

Detecció del Bosó de Higgs amb Xarxes Neuronals

Comparativa entre MLP i Graph Neural Networks

Aprenentatge Automàtic II (2025–2026)

Grau en Estadística Aplicada — UAB

Pau Verdejo Gallardo

Juny 2026

Índex

1	Introducció i motivació	2
1.1	Justificació de l'ús d'una GNN	2
2	Conjunt de dades	2
2.1	Variables de baix nivell (21)	2
2.2	Variables d'alt nivell (7)	3
3	Anàlisi exploratòria i preprocessament	4
3.1	Preprocessament	5
3.1.1	Transformació de variables amb cues pesades	5
3.1.2	Estandardització	5
3.1.3	Partició de les dades	6
4	Arquitectura base: Multilayer Perceptron	6
4.1	Formalització	6
4.2	Funció de pèrdua i optimització	7
4.3	Regularització	7
4.4	Configuració i diagnòstic	7
5	Arquitectura avançada: Graph Neural Network	8
5.1	Motivació: partícules com a graf	8
5.2	Message Passing Neural Networks	8
5.3	Construcció del graf	8
5.4	EdgeConv	9
5.5	Pooling, classificació i configuració	9
6	Comparativa de models	10
6.1	Mètriques d'avaluació	10
6.2	Resultats	10
6.3	Discussió crítica	11
6.4	Un baseline no neuronal: XGBoost	11
7	Avaluació final i anàlisi d'inferència	12
8	Conclusions	12
8.1	Lliçons apreses	13
8.2	Limitacions i línies futures	13

1 Introducció i motivació

La detecció del bosó de Higgs als acceleradors de partícules com el LHC del CERN constitueix un dels problemes de classificació binària més emblemàtics de la física d'altres energies. El repte central rau en la dificultat de separar el senyal (esdeveniments que contenen el bosó de Higgs) del soroll de fons (processos físics que generen signatures similars als detectors).

L'any 2014, Baldi et al. [1] van demostrar que una xarxa neuronal profunda entrenada sobre variables cinemàtiques de baix nivell pot aprendre implícitament les interaccions no lineals entre partícules i superar l'ús de variables d'alt nivell construïdes manualment per físics. El seu millor model (una MLP) va assolir un AUC de 0.885 sobre la totalitat de les dades.

En aquest treball s'explora si imposar l'estructura relacional de les dades com a inductiva bias (és a dir, codificar explícitament que el problema tracta sobre interaccions entre partícules) produeix models més eficients que una MLP plana. Per fer-ho, es compara una MLP amb una Graph Neural Network (GNN), ambdues entrenades amb les mateixes dades i sobre les mateixes 21 variables de baix nivell.

1.1 Justificació de l'ús d'una GNN

Una MLP rep totes les variables com un vector sense estructura: no distingeix quines variables pertanyen al leptó, quines als jets, ni com es relacionen entre si. Amb prou dades i capacitat, pot aprendre aquestes correlacions implícitament —com Baldi et al. demostren— però sense cap garantia d'eficiència ni de generalització.

Una GNN, en canvi, construeix explícitament un graf on cada partícula és un node i les arestes representen interaccions possibles. Això li imposa dos biaixos inductius físicament correctes: que les relacions entre partícules (masses invariants, angles de separació) són la informació clau, i que el resultat no ha de dependre de l'ordre en què es llisten les partícules. Quan el dataset és gran, la MLP pot compensar l'absència d'aquest biaix; quan és petit, la GNN hauria d'aprendre la solució de forma estadísticament més eficient.

2 Conjunt de dades

Taula 1: Fitxa tècnica del dataset HIGGS.

Característica	Valor
Font	UCI ML Repository
Mostres totals	11 000 000
Mostres utilitzades	1 000 000
Variables	28 (21 baix nivell + 7 alt nivell)
Variable objectiu	Binària (1 = senyal, 0 = fons)
Balanç de classes	53% senyal, 47% fons
Valors absents	Cap (simulació Monte Carlo)

El dataset HIGGS [1] conté 11 milions d'esdeveniments simulats de col·lisions protó-protó. Cada event es correspon amb una col·lisió i està etiquetat com a senyal (el bosó de Higgs s'ha produït i ha decaïgut via $H \rightarrow \tau\tau$) o fons (processos similars però sense bosó de Higgs). Cada event es descriu amb 28 variables, dividides en dos grups.

2.1 Variables de baix nivell (21)

Mesures cinemàtiques directes del detector, agrupades per objecte físic:

Leptó. Un leptó (electró o muó) prové de la desintegració d'un dels tauons. Es mesuren el moment transversal p_T^ℓ , la pseudorapiditat η^ℓ i l'angle azimutal ϕ^ℓ . La pseudorapiditat es defineix com $\eta = -\ln \tan(\theta/2)$, on θ és l'angle polar respecte al feix; és la coordenada angular estàndard en col·lisionadors perquè la producció de partícules és aproximadament uniforme en η .

Energia transversal perduda (MET). Els neutrins no es detecten i deixen un desequilibri de moment en el pla transversal. Es registren la seva magnitud E_T^{miss} i la direcció azimutal ϕ^{miss} .

Jets. Un jet és un raig de partícules produït per la fragmentació d'un quark o gluó. Es registren fins a quatre jets per event (ordenats per p_T decreixent), cadascun caracteritzat per $p_T^{j_i}$, η^{j_i} , ϕ^{j_i} i una puntuació de b -tagging b_i que indica la probabilitat que el jet provingui d'un quark b .

2.2 Variables d'alt nivell (7)

Masses invariants construïdes combinant les variables de baix nivell. La massa invariant d'un sistema de partícules és:

$$m = \sqrt{\left(\sum_i p_i\right)^2}, \quad (1)$$

on p_i és el quadrivector energia-moment de cada partícula. La Taula 2 descriu cadascuna.

Taula 2: Variables d'alt nivell i la seva interpretació física.

Variable	Components	Interpretació
m_{jj}	Jets 1 i 2	Massa di-jet; discriminant clau per a producció VBF
m_{jjj}	Jets 1, 2 i 3	Massa tri-jet; contra fons QCD multijet
$m_{\ell\nu}$	Leptó i MET	Massa transversal del W en $\tau \rightarrow \ell\nu$
$m_{j\ell\nu}$	Jet 1, leptó i MET	Reconstrueix el quark top en el fons $t\bar{t}$
m_{bb}	Jets amb més b -tag	Massa del par $b\bar{b}$; pic a 125 GeV per $H \rightarrow b\bar{b}$
m_{Wbb}	W , jets b	Reconstrueix $t \rightarrow Wb$
m_{WWbb}	Dos W i jets b	Reconstrueix el sistema complet $t\bar{t}$

Baldi et al. van demostrar que una xarxa profunda entrenada només amb les 21 variables de baix nivell assoleix el mateix rendiment que quan s'inclouen les 7 d'alt nivell, cosa que indica que la xarxa aprèn implícitament les combinacions rellevants. Per això, en aquest treball s'utilitzen exclusivament les 21 variables de baix nivell.

3 Anàlisi exploratòria i preprocessament




Figura 1: Distribucions marginals de les 12 primeres variables de baix nivell. Blau: senyal ($y = 1$); Vermell: fons ($y = 0$).

De la Figura 1 s'observa que les distribucions de senyal i fons se solapen considerablement en totes les variables, cosa que indica que cap variable individual té poder discriminant suficient per si sola. Les variables de moment transversal (p_T) mostren distribucions esbiaixades positivament: la majoria d'events es concentren a valors baixos amb una cua cap a valors alts, i el senyal tendeix lleugerament cap a moments més elevats. Les variables angulars (η , ϕ) i la direcció del MET presenten distribucions aproximadament uniformes i gairebé idèntiques entre classes; el seu poder discriminant rau en la seva combinació amb altres variables. Això motiva l'ús d'un model capaç de capturar correlacions entre variables.




Figura 2: Matriu de correlació de Pearson de les 21 variables de baix nivell (triangle inferior).

La matriu de correlació (Figura 2) mostra correlacions moderades entre els moments transversals dels jets ($r \approx 0.3\text{--}0.5$). Les variables angulars del mateix jet i les puntuacions de b -tag estan poc correlacionades amb la resta. No hi ha col·linealitat extrema que comprometi l'entrenament.

3.1 Preprocessament

3.1.1 Transformació de variables amb cues pesades

Les variables p_T i el MET presenten asimetria positiva marcada ($|\gamma_1| > 1$). S'aplica la transformació de Yeo–Johnson [6]:

$$\psi_\lambda(x) = \begin{cases} \frac{(x+1)^\lambda - 1}{\lambda} & \lambda \neq 0, x \geq 0, \\ \ln(x+1) & \lambda = 0, x \geq 0, \\ -\frac{(-x+1)^{2-\lambda} - 1}{2-\lambda} & \lambda \neq 2, x < 0, \\ -\ln(-x+1) & \lambda = 2, x < 0, \end{cases} \quad (2)$$

on λ s'estima per màxima versemblança sobre cada variable. A diferència de la transformació logarítmica, Yeo–Johnson admet valors negatius i zeros, cosa que la fa aplicable a qualsevol variable sense restriccions de domini.

3.1.2 Estandardització

Després de la transformació, s'aplica una estandardització z -score:

$$\tilde{x}_j = \frac{x_j - \hat{\mu}_j}{\hat{\sigma}_j + \varepsilon}, \quad j = 1, \dots, 21, \quad (3)$$

on $\hat{\mu}_j$ i $\hat{\sigma}_j$ s'estimen exclusivament sobre el conjunt d'entrenament per evitar data leakage, i $\varepsilon = 10^{-8}$ prevé la divisió per zero.




Figura 3: Distribucions de les variables de moment post-transformació Yeo–Johnson i estandardització. Les distribucions s'aproximen a una gaussiana estàndard.

Com s'observa a la Figura 3, les cues asimètriques queden substancialment reduïdes. Això facilita l'optimització de la xarxa, ja que redueix la magnitud dels gradients extrems als primers passos d'entrenament.

3.1.3 Partició de les dades

Les dades es divideixen de forma estratificada (mantenint el balanç de classes):

Entrenament: 70% = 700 000 mostres,

Validació: 15% = 150 000 mostres,

Test: 15% = 150 000 mostres.

Observació 3.1. El conjunt de test no s'utilitza en cap decisió de modelatge (selecció d'hiperparàmetres ni early stopping). Únicament s'avalua un cop seleccionat el model final.

4 Arquitectura base: Multilayer Perceptron

4.1 Formalització

Una xarxa completament connectada de L capes ocultes aplica successivament:

$$\mathbf{h}^{(0)} = \mathbf{x} \in \mathbb{R}^{21}, \quad (4)$$

$$\mathbf{h}^{(\ell)} = \phi\left(\mathbf{W}^{(\ell)}\mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}\right), \quad \ell = 1, \dots, L, \quad (5)$$

on $\mathbf{W}^{(\ell)}$ i $\mathbf{b}^{(\ell)}$ són els paràmetres entrenables i ϕ és la funció d'activació ReLU: $\text{ReLU}(z) = \max(0, z)$. La sortida final és:

$$\hat{y} = \sigma\left(\mathbf{W}^{(L+1)}\mathbf{h}^{(L)} + \mathbf{b}^{(L+1)}\right) \in (0, 1), \quad (6)$$

interpretada com $\hat{y} = P(Y = 1 \mid \mathbf{x})$.

4.2 Funció de pèrdua i optimització

S'utilitza l'entropia creuada binària (BCE):

$$\mathcal{L}(\theta) = -\frac{1}{N} \sum_{i=1}^N [y_i \log \hat{y}_i + (1 - y_i) \log(1 - \hat{y}_i)]. \quad (7)$$

Minimitzar la BCE és equivalent a maximitzar la versemblança sota un model de Bernoulli. S'utilitza l'optimitzador Adam [2]:

$$m_t = \beta_1 m_{t-1} + (1 - \beta_1) \nabla_{\theta} \mathcal{L}_t, \quad (8)$$

$$v_t = \beta_2 v_{t-1} + (1 - \beta_2) (\nabla_{\theta} \mathcal{L}_t)^2, \quad (9)$$

$$\theta_t = \theta_{t-1} - \frac{\eta}{\sqrt{\hat{v}_t} + \varepsilon} \hat{m}_t, \quad (10)$$

amb $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\eta_0 = 10^{-3}$. S'aplica un scheduler ReduceLROnPlateau: si la pèrdua de validació no millora durant $p = 4$ èpoques, $\eta \leftarrow 0.5 \cdot \eta$.

4.3 Regularització

S'utilitzen tres tècniques de regularització combinades. La normalització per batch (BatchNorm) [3] normalitza les activacions a cada capa:

$$\text{BN}(\mathbf{h}) = \gamma \odot \frac{\mathbf{h} - \hat{\mu}_{\mathcal{B}}}{\sqrt{\hat{\sigma}_{\mathcal{B}}^2 + \varepsilon}} + \beta, \quad (11)$$

estabilitzant les distribucions intermèdies i actuant com a regularitzador implícit. El Dropout apaga aleatòriament cada neurona amb probabilitat p durant l'entrenament:

$$\tilde{h}_j = \frac{1}{1-p} \cdot \mathbf{1}_{u_j > p} \cdot h_j, \quad u_j \sim \text{Uniform}(0, 1), \quad (12)$$

on el factor $\frac{1}{1-p}$ garanteix que l'esperança de la sortida sigui igual en entrenament i inferència. Finalment, la regularització L2 afegeix una penalització sobre els pesos:

$$\mathcal{L}_{\text{reg}}(\theta) = \mathcal{L}(\theta) + \frac{\lambda}{2} \sum_{\ell} \|\mathbf{w}^{(\ell)}\|_F^2. \quad (13)$$

4.4 Configuració i diagnòstic

Taula 3: Configuració final de la MLP.

Hiperparàmetre	Valor
Capes ocultes	4 (256 → 256 → 128 → 64)
Activació	ReLU
Dropout p	0.3
η_0 (Adam)	10^{-3}
Weight decay λ	10^{-4}
Batch size	2048
Paràmetres totals	114 049

L'arquitectura [256, 256, 128, 64] és un embut progressiu: les primeres capes capturen representacions riques de les variables crues i les posteriors comprimeixen la informació cap a la classificació final.




Figura 4: Corbes d’aprenentatge de la MLP. Esquerra: pèrdua BCE. Dreta: AUC-ROC. Blau: entrenament; Vermell: validació.

Les corbes (Figura 4) mostren convergència estable al llarg de les 60 èpoques. La pèrdua de validació final (≈ 0.551) és lleugerament inferior a la d’entrenament (≈ 0.572), cosa habitual quan s’utilitzen Dropout i BatchNorm: aquestes regularitzacions s’apliquen durant l’entrenament però no durant la inferència, de manera que el model efectiu en validació és efectivament més gran. No constitueix underfitting sinó un artefacte esperat. El scheduler redueix la taxa d’aprenentatge cap a l’època 35, produint un descens addicional visible a les corbes. La MLP assoleix un AUC de validació de 0.790 i de test de 0.788, valors molt propers que confirmen que no hi ha sobreajust.

5 Arquitectura avançada: Graph Neural Network

5.1 Motivació: partícules com a graf

En una col·lisió al LHC, cada event produeix un conjunt de partícules detectades. Aquesta estructura és inherentment relacional: la variable objectiu depèn no sols de les propietats individuals de cada partícula sinó de les seves interaccions per parelles (masses invariants, angles de separació, etc.). Una MLP tracta totes les variables com un vector pla, forçant la xarxa a aprendre aquestes correlacions de manera implícita. Una GNN construeix explícitament un graf $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ on cada partícula és un node i les arestes representen interaccions, i propaga informació a través d’aquesta estructura. L’inductive bias resultant — que el problema té estructura relacional i que el resultat no ha de dependre de l’ordre en què es llisten les partícules — és físicament adequat.

5.2 Message Passing Neural Networks

El Message Passing (MPNN) [4] descriu la propagació d’informació en un graf: en cada capa k , cada node agrega informació dels seus veïns i actualitza la seva representació:

$$\mathbf{m}_i^{(k)} = \bigoplus_{j \in \mathcal{N}(i)} \phi\left(\mathbf{h}_i^{(k-1)}, \mathbf{h}_j^{(k-1)}\right), \quad (14)$$

$$\mathbf{h}_i^{(k)} = \psi\left(\mathbf{h}_i^{(k-1)}, \mathbf{m}_i^{(k)}\right), \quad (15)$$

on $\mathcal{N}(i)$ és el conjunt de nodes veïns de i , $\bigoplus$ és una operació permutation-invariant (suma, màxim o mitjana), i ϕ, ψ són xarxes neuronals entrenables.

5.3 Construcció del graf

Les 21 variables es reparteixen entre 6 partícules, cadascuna com un node:

Node	Variables	Dimensió
Leptó	p_T, η, ϕ	3
MET	magnitud, ϕ	2
Jets 1–4	$p_T, \eta, \phi, b\text{-tag}$	4

Les partícules amb menys de 4 features (leptó: 3; MET: 2) s'omplen amb zero-padding fins a $d_{\text{node}} = 4$.

Respecte als jets de baixa energia: en la simulació de Monte Carlo els jets absents no s'eliminen sinó que apareixen amb p_T molt baix. Durant el desenvolupament del treball es va provar d'excloure els nodes de jets amb $p_T \approx 0$, però el model va empitjorar respecte a la MLP. En incloure'ls, la GNN la superava. Això indica que els valors de p_T baix, un cop transformats, segueixen aportant informació discriminant (la multiplicitat efectiva de jets és en si mateixa una senyal). Tots els events produeixen doncs un graf de $|\mathcal{V}| = 6$ nodes.

S'utilitza un graf completament connectat (K_6): totes les partícules es consideren veïnes entre si, amb $6 \times 5 = 30$ arestes dirigides per event. Això garanteix que la GNN tingui accés a totes les interaccions per parelles possibles.

5.4 EdgeConv

S'utilitza l'operació EdgeConv [5], que calcula el missatge entre nodes com:

$$\mathbf{m}_{ij} = h_{\Theta}(\mathbf{h}_i^{(k-1)}, \mathbf{h}_j^{(k-1)} - \mathbf{h}_i^{(k-1)}), \quad (16)$$

on h_{Θ} és una MLP de dues capes. La diferència $\mathbf{h}_j - \mathbf{h}_i$ captura la variació relativa entre partícules. L'agregació sobre els veïns és un màxim element a element:

$$\mathbf{h}_i^{(k)} = \max_{j \in \mathcal{N}(i)} \mathbf{m}_{ij}, \quad (17)$$

operació permutation-invariant. S'afegeix una connexió residual:

$$\mathbf{h}_i^{(k)} \leftarrow \mathbf{h}_i^{(k)} + \mathbf{W}_{\text{skip}} \mathbf{h}_i^{(k-1)}. \quad (18)$$

Cal notar que EdgeConv va ser dissenyat per a núvols de punts amb centenars o milers de nodes. Amb $|\mathcal{V}| = 6$ nodes i un graf complet, cada node ja veu tots els altres en la primera capa, de manera que les capes addicionals reprocessen informació ja disponible. Arquitectures pensades per a grafs petits com les Interaction Networks o els transformers sobre conjunts de partícules podrien ser més adequades. Malgrat aquesta limitació, els resultats mostren que la GNN supera la MLP en +8.73% d'AUC.

5.5 Pooling, classificació i configuració

Després de $K = 3$ capes EdgeConv, s'aplica un global mean pooling per obtenir una representació de tot l'event:

$$\mathbf{h}_{\mathcal{G}} = \frac{1}{|\mathcal{V}|} \sum_{i \in \mathcal{V}} \mathbf{h}_i^{(K)}, \quad (19)$$

que passa per una MLP classificadora per produir la probabilitat de senyal: $\hat{y} = \sigma(\text{MLP}_{\text{cls}}(\mathbf{h}_{\mathcal{G}}))$.

Taula 4: Configuració de la GNN.

Hiperparàmetre	Valor
Capes EdgeConv	3
Dimensió hidden	128
Classificador	[128, 64, 1]
Pooling	Global Mean
Dropout p	0.3
Dimensió de node	4 (zero-padding)
Graf	Completament connectat (K_6 , 30 arestes)
Batch size	1 024
Paràmetres totals	175 489

6 Comparativa de models

6.1 Mètriques d'avaluació

La mètrica principal és l'AUC-ROC, que mesura la capacitat discriminant de forma independent del llindar de classificació:

$$\text{AUC-ROC} = P(\hat{y}_{y=1} > \hat{y}_{y=0}), \quad (20)$$

és a dir, la probabilitat que un exemple positiu rebi una puntuació superior a la d'un negatiu aleatori.

S'utilitza també la significança estadística del senyal a un llindar τ :

$$\text{Sig}(\tau) = \frac{S(\tau)}{\sqrt{B(\tau)}}, \quad (21)$$

on $S(\tau)$ i $B(\tau)$ són el nombre d'events de senyal i fons classificats per sobre de τ . Aquesta és la mètrica que usen els físics experimentals per decidir si un descobriment és estadísticament significatiu.

6.2 Resultats

Taula 5: Comparativa de models sobre el conjunt de test ($n = 150\,000$).

Model	AUC-ROC	Accuracy	Paràm.	Sig. màx.
MLP (21 var.)	0.788	0.716	114 049	405.6 ($\tau = 0.64$)
GNN EdgeConv (21 var.)	0.857	0.775	175 489	574.8 ($\tau = 0.87$)

La GNN supera la MLP en +6.9 punts d'AUC (millora relativa del +8.73%) i en +41.9% de significança màxima. Ambdós models queden per sota del benchmark de Baldi et al., cosa atribuïble a l'ús d'1M de mostres en lloc dels 11M complets i a l'arquitectura GNN relativament senzilla.





Figura 5: Esquerra: corbes ROC.). Dreta: distribució dels scores $\hat{y}$ per a senyal i fons.

La corba ROC de la GNN domina estrictament la de la MLP a tot l'eix de FPR, indicant que la modelització explícita de les relacions inter-partícula és beneficiosa per a qualsevol compromís entre sensibilitat i especificitat. La GNN produeix scores més polaritzats (pics pronunciats a 0 i a 1), mentre que la MLP acumula més probabilitat a la zona central ($\hat{y} \in [0.3, 0.7]$) on senyal i fons es confonen.



(a) AUC de validació per època.


(b) Significança $S/\sqrt{B}$ vs. llindar τ .

Figura 6: Esquerra: la GNN assoleix $AUC \approx 0.80$ a les 10 primeres èpoques, mentre la MLP necessita ≈ 20 . Dreta: la GNN assoleix significança màxima de 574.8 a $\tau = 0.87$.

La GNN assoleix $AUC \approx 0.80$ ja a les primeres 10 èpoques, mentre que la MLP necessita ≈ 20 per arribar al mateix nivell. Aquesta arrencada més ràpida és consistent amb la hipòtesi que l'inductiu bias relacional facilita l'aprenentatge en les fases inicials. Posteriorment ambdues evolucionen de manera similar fins als seus respectius plateaux (≈ 0.857 per a la GNN, ≈ 0.788 per a la MLP).




Figura 7: Corbes d'aprenentatge de la GNN. Esquerra: pèrdua BCE. Dreta: AUC-ROC. La pèrdua de validació segueix molt de prop la d'entrenament, sense signes d'overfitting.

6.3 Discussió crítica

Els resultats permeten respondre la pregunta central: explotar l'estructura relacional de les partícules millora el rendiment? La resposta és sí, de forma clara i consistent en totes les mètriques. Cal però contextualitzar:

- La GNN utilitza $\approx 1.5\times$ més paràmetres que la MLP (175K vs. 114K). Una part de la millora podria atribuir-se a la major capacitat. Una comparativa a nombre de paràmetres iguals confirmaria si la millora és purament estructural.
- Ambdós models queden per sota del benchmark, fet que esperavem. La diferència respecte a la GNN (≈ 3 punts) s'explica per l'ús d'1/10 de les dades.
- La millora no és un artefacte de l'arquitectura sinó una conseqüència de l'inductiu bias: forçar la xarxa a aprendre representacions per a cadascuna de les 6 partícules i les seves interaccions és una parametrització més adequada físicament que tractar les 21 variables com un vector pla.

6.4 Un baseline no neuronal: XGBoost

Com a punt de referència addicional –no entrenat empíricament en aquest treball– val la pena situar XGBoost [8] en la comparativa. Es tracta d'una implementació eficient de *gradient boosting* sobre arbres de decisió, utilitzada habitualment com a baseline fort per a dades tabulars gràcies a la seva rapidesa d'entrenament i a la seva capacitat de gestionar grans volums de dades sense necessitat de dissenyar cap arquitectura específica. De fet, el

mateix article original de Chen i Guestrin [8] utilitza precisament el dataset HIGGS com un dels seus principals bancs de proves d'escalabilitat: amb una submostra d'1M d'events –la mateixa escala de dades emprada en aquest treball– reporten un AUC de test de 0.830 amb l'algorisme *exact greedy* (500 arbres), pràcticament idèntic al que assoleix scikit-learn sobre les mateixes dades, però en una fracció del temps computacional.

A diferència de la MLP i la GNN, XGBoost no aprèn cap representació interna: opera directament sobre les 21 variables tabulars i construeix particions seqüencials basades en guanys d'informació, sense cap noció –ni explícita ni implícita– d'estructura relacional entre partícules. Per això constitueix un contrapunt interessant: permetria comprovar si el cost addicional d'una xarxa neuronal (i, en particular, el biaix inductiu relacional de la GNN) es tradueix en una millora real respecte a un model d'arbres ben afinat, sense necessitat d'entrenament prolongat ni d'ajust d'arquitectura. Incorporar el metode juntament amb una cerca d'hiperparàmetres bàsica (profunditat dels arbres, *learning rate*, nombre d'estimadors) – és la línia de treball futur més immediata.

7 Avaluació final i anàlisi d'inferència




Figura 8: Quatre casos individuals del conjunt de test (GNN). Per a cada cas es mostren els z -scores de les 21 variables. Verd: vertader positiu; Blau: vertader negatiu; Vermell: fals positiu; Taronja: fals negatiu.

El veritable positiu ($score = 0.945$) presenta moments transversals dels jets elevats i valors de b -tag positius, coherents amb la topologia de decaïment del Higgs. El veritable negatiu ($score = 0.047$) mostra moments baixos i una configuració angular poc típica del senyal.

El cas més interessant és el fals positiu ($score = 0.955$): un esdeveniment de fons classificat com a senyal amb alta confiança. Presenta una configuració de jets molt similar a la del veritable positiu (moments elevats, presència de b -jets), probablement corresponent a un procés físic que imita la topologia del Higgs. Aquests errors són difícils d'evitar sense informació addicional que permeti separar aquests dos esdeveniments amb topologies gairebé idèntiques.

Finalment, el fals negatiu ($score = 0.051$) és un esdeveniment de senyal amb valors extrems d'angle ϕ i pseudorapiditat, fora de la distribució habitual. Tot i que aparentment presenta característiques pròpies d'un veritable negatiu, es tracta d'un cas atípic molt aïllat on aquesta cinemàtica correspon realment a un senyal.

8 Conclusions

1. La MLP de 4 capes [256, 256, 128, 64] assoleix una $AUC = 0.788$ sobre el conjunt de test, treballant exclusivament amb les 21 variables de baix nivell. Això és una petita demostració del treball de [1]; en aquest cas, la diferència respecte a l'AUC és atribuïble a l'ús de menys paràmetres i dades d'entrenament.
2. La GNN amb EdgeConv millora l'AUC en +6.9 punts (0.857 vs. 0.788), fet que suposa una millora relativa del +8.73%. Aquesta millora és consistent en totes les mètriques i en la velocitat de convergència. Tot i la diferència en el nombre de paràmetres, aquest increment en el rendiment és atribuïble principalment a l'inductiu bias de l'arquitectura.
3. Amb 1 milió de mostres (1/10 de les dades originals) i 175 000 paràmetres (enfrent dels aproximadament 300 000 del model complet), la GNN queda tan sols ≈ 3 punts per sota del benchmark de l'article original. Aquest fet indica que l'inductiu bias permet que el model s'apropi als resultats de referència amb un cost computacional substancialment inferior.

4. La transformació Yeo–Johnson prèvia a l'estandardització és essencial per a la convergència en variables amb cues pesades. La combinació BatchNorm + Dropout ($p = 0.3$) controla de manera efectiva el overfitting.

8.1 Lliçons apreses

L'interès inicial per aquest treball va sorgir de la naturalesa del conjunt de dades en si mateix; no obstant això, durant la seva realització, el procés d'aprenentatge ha estat profund i transversal.

La lliçó principal que s'extreu d'aquest projecte és la importància d'entendre exhaustivament la naturalesa de les variables abans de dissenyar qualsevol arquitectura. Comprendre exactament què representa cada variable i quina informació física i estadística aporta és fonamental. Només des d'aquesta comprensió prèvia és possible dissenyar una xarxa neuronal adequada, capaç d'incorporar el *inductive bias* correcte per modelar el problema de manera eficient.

A nivell tècnic, aquest projecte m'ha permès consolidar els coneixements sobre xarxes neuronals, aprofundint especialment en les respectives estratègies d'entrenament. Així mateix, l'estudi de les GNN ha suposat un repte. Tot i la dificultat conceptual inicial d'allunyar-se dels models tabulars clàssics, la combinació de recursos formatius externs i el suport d'eines d'intel·ligència artificial m'han permès desenvolupar una intuïció sòlida sobre com aquestes xarxes capturen i exploten l'estructura relacional de les dades.

8.2 Limitacions i línies futures

Entre les limitacions d'aquest estudi destaquen: l'ús d'una submostra del conjunt de dades original, l'arquitectura escollida per a la GNN (relativament senzilla), el mètode de *message passing* implementat (EdgeConv), la topologia utilitzada per als grafs, i la manca d'una comparativa empírica amb un baseline no neuronal com XGBoost (vegeu Secció 6).

Si es disposés dels recursos computacionals necessaris per operar amb la mostra sencera, es podria fer una comparació directa entre aquesta GNN i la MLP descrita per [1], fet que proporcionaria una conclusió més robusta i validada. Actualment, existeixen arquitectures GNN amb un *inductive bias* físicament més estricte que donen peu a un aprenentatge més expressiu i eficient, com ara els models Lorentz-equivariants (LorentzNet [7]). Finalment, els grafs es podrien haver construït d'una altra manera; en comptes de connectar totes les partícules entre si, es podria haver considerat la proximitat espacial o cinemàtica de les partícules per formar un graf k -NN.

Referències

- [1] P. Baldi, P. Sadowski, D. Whiteson, *Searching for exotic particles in high-energy physics with deep learning*, Nature Communications, 5(1):4308, 2014.
- [2] D. P. Kingma, J. Ba, *Adam: A method for stochastic optimization*, arXiv:1412.6980, 2014.
- [3] S. Ioffe, C. Szegedy, *Batch normalization: Accelerating deep network training*, ICML 2015.
- [4] J. Gilmer et al., *Neural message passing for quantum chemistry*, ICML 2017.
- [5] Y. Wang et al., *Dynamic graph CNN for learning on point clouds*, ACM Transactions on Graphics, 38(5), 2019.
- [6] I.-K. Yeo, R. A. Johnson, *A new family of power transformations to improve normality or symmetry*, Biometrika, 87(4):954–959, 2000.
- [7] A. Bogatskiy et al., *Lorentz group equivariant neural network for particle physics*, ICML 2022.
- [8] T. Chen, C. Guestrin, *XGBoost: A scalable tree boosting system*, Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD), 785–794, 2016.