



UNIVERSITAT AUTÒNOMA DE BARCELONA

APRENENTATGE AUTOMÀTIC

A la recerca de nous mons: Models de
classificació per a la detecció
d'exoplanetes

Integrantes del grupo:

Pol ORTIZ

Rubén SORIA

Pau VERDEJO

Profesora:

Anabel BLASCO

6 d'octubre de 2026

Índex

1	Introducció	2
1.1	Breu introducció al tema de l'aprenentatge automàtic	2
1.2	Motivació i justificació de la tria del conjunt de dades	2
1.3	Objectius específics del treball	2
2	Descripció del conjunt de dades	3
2.1	Origen del conjunt de dades	3
2.2	Descripció i justificació de les variables	3
2.2.1	Variable resposta	3
2.2.2	Variables Categòriques	3
2.2.3	Variables numèriques:	4
3	Exploració de les dades	6
4	Aplicació d'algorismes d'aprenentatge automàtic	9
4.1	Algorismes empletas i justificació	9
4.2	Mètriques d'avaluació i rigor estadístic	10
4.3	Aplicació dels algoritmes i entrenament dels models amb el conjunt de dades	11
4.3.1	Normalització: Standard Scaler	11
4.3.2	Estratègia d'ajust d'hiperparàmetres	11
5	Resultats i interpretació	12
5.1	Presentació dels resultats obtinguts	12
5.1.1	K-NN	12
5.1.2	Màquines de Suport Vectorial (SVM)	12
5.1.3	Random Forest	13
5.1.4	K-fold validation	14
5.2	Comparació final i selecció del model	14
5.3	Interpretació dels resultats en el context del conjunt de dades	15
6	Conclusions i Treball Futur	16
6.1	Conclusions generals	16
6.2	Limitacions del treball	16
6.3	Propostes de treball futur	17
7	Annexos	18
7.1	Codi utilitzat	18
8	Bibliografia i Webgrafia	26

1 Introducció

1.1 Breu introducció al tema de l'aprenentatge automàtic

La **Intel·ligència Artificial (IA)** és la disciplina que engloba el conjunt d'algoritmes i tècniques dissenyades perquè una màquina imiti funcions cognitives pròpies dels humans, com ara l'aprenentatge o la resolució de problemes complexos. Dins d'aquest àmbit trobem l'**Aprenentatge Automàtic** (o *Machine Learning*), un subcamp que utilitza l'estadística i les matemàtiques per crear models capaços d'analitzar dades i realitzar prediccions. Aquest concepte rep el seu nom de la capacitat dels models per "auto-aprendre" a partir de les bases de dades.




Figura 1: Diagrama de Venn mostrant la relació entre IA i ML.

Pel que fa a la implementació tècnica, existeix una àmplia varietat de models segons l'objectiu del problema. Els més fonamentals inclouen la **Regressió Lineal i Logística**, utilitzades per a prediccions numèriques i classificacions simples respectivament. Quan es requereix una major robustesa o interpretabilitat, sovint es recorre als **Arbres de Decisió** i la seva evolució, el **Random Forest**, així com a les **Màquines de Suport Vectorial (SVM)**, molt eficaces per definir fronteres clares entre classes. D'altra banda, trobem mètodes senzills basats en la proximitat com el **K-Nearest Neighbors (K-NN)**.

1.2 Motivació i justificació de la tria del conjunt de dades

La cerca d'exoplanetes (planetes fora del nostre sistema solar) és un dels camps més actius a l'astrofísica moderna. I des del llançament del telescopi espacial Kepler de la NASA al 2009, la quantitat i qualitat de dades relacionades amb aquest camp ha crescut exponencialment. La missió Kepler no només buscava planetes, sinó que intentava respondre a una pregunta que la humanitat s'ha fet desde fa molt temps: estem sols a l'univers? Amb les grans quantitats de dades que es generen de senyals que podrien o no ser exoplanetes, neix la necessitat d'automatitzar la classificació d'aquestes senyals.

Per aquest treball, s'ha escollit un conjunt de dades que conté els resultats de la cerca del telescopi Kepler, amb etiquetes que indiquen si les senyals detectades han sigut confirmades com exoplanetes o són falsos positius. Aquestes dades, a part de ser fiables (ja que provenen de la NASA) tenen bastant més de 5000 observacions i moltes variables de diferents tipus.

1.3 Objectius específics del treball

L'objectiu principal d'aquest treball és desenvolupar i avaluar un model d'aprenentatge automàtic capaç de determinar, amb la màxima precisió possible, si una senyal captada pel telescopi Kepler prové, o no d'un exoplaneta. Aquesta tasca de classificació es realitzarà exclusivament a partir de les variables del conjunt de dades seleccionat, permetent

així identificar la naturalesa dels cossos espacials basant-se únicament en els paràmetres observats.

2 Descripció del conjunt de dades

2.1 Origen del conjunt de dades

El conjunt de dades utilitzat, titulat "Kepler Exoplanet Search Results", prové del NASA Exoplanet Archive, que és una base de dades astronòmiques gestionada per l'Institut de Tecnologia de Califòrnia (en col·laboració amb la NASA). I son el producte de les observacions realitzades per el telescopi Kepler. El telescopi Kepler observa moltes estrelles simultàniament, i quan detecta que una estrella podria tenir algún planeta, les senyals d'aquesta estrella (cada senyal es considera un posible exoplaneta) esdevenen KOI's (Kepler Object of Interest), i aquest fa una medició de moltes variables d'aquesta estrella. Les observacions del conjunt de dades són aquestes medicions que fa el telescopi, per tant només tenim observacions de possibles exoplanetes, no de qualsevol tipus de senyal.

Com a observació, la base de dades és acumulativa, és a dir, les mesures s'han anat fent a través de molt temps, i probablement s'ha fet una mesura en concret més d'una vegada. A la base de dades, no apareixen les mesures repetides, sino que només són les mesures més noves i que es consideren més correctes. Això garanteix unes dades de més qualitat.

2.2 Descripció i justificació de les variables

2.2.1 Variable resposta

La variable objectiu del nostre model és `koi_disposition`, la qual presenta tres categories possibles:

- **CONFIRMED:** L'objecte és un exoplaneta verificat.
- **FALSE POSITIVE:** Es descarta que l'objecte sigui un planeta (fals positiu).
- **CANDIDATE:** L'objecte presenta característiques prometedores però encara no ha estat confirmat oficialment.

Atès que l'objectiu principal del projecte és realitzar una classificació binària estricta basada en certes, s'ha optat per descartar totes les instàncies etiquetades com a *CANDIDATE*. D'aquesta manera, el model s'entrenarà exclusivament amb dades ja resoltes, evitant introduir ambigüitat en el procés d'aprenentatge.

2.2.2 Variables Categòriques

El conjunt de dades inclou quatre variables categòriques binàries (0 o 1) conegudes com a *False Positive Flags*. Aquestes variables indiquen si s'ha detectat alguna anomalia durant el procés d'anàlisi fotomètrica que suggereixi que l'objecte no és un planeta.

Les quatre variables són les següents:

koi_fpflag_nt (Not Transit-like): S'activa (valor 1) quan la corba de llum observada no presenta la forma característica d'un trànsit planetari, suggerint que la disminució de brillantor es deu a soroll instrumental o altres factors.

koi_fpflag_ss (Stellar Eclipse): Indica la presència d'un eclipsi estel·lar. S'activa quan es detecten fenòmens propis de sistemes binaris (dues estrelles orbitant-se), com ara eclipsis secundaris, cosa que descarta que l'objecte sigui un planeta.

koi_fpflag_co (Centroid Offset): S'activa quan es detecta un desplaçament significatiu en el centre de llum de la imatge durant el trànsit. Això acostuma a indicar que la font de l'eclipsi no és l'estrella objectiu, sinó una estrella de fons propera.

koi_fpflag_ec (Ephemeris Contamination): Senyalitza que la periodicitat i la fase del trànsit coincideixen amb les d'un altre objecte proper ja conegut, o que els píxels estan contaminats per la llum d'una estrella veïna.

La importància d'aquestes variables rau en el fet que un valor de 1 en qualsevol d'elles augmenta dràsticament la probabilitat que el candidat sigui un *Fals Positiu*, aquest fet pot ser molt útil perquè el model aprengui degudament.

2.2.3 Variables numèriques:

Hi han diverses varibales numèriques que donen informació física tant de la estrella (el sol del possible exoplaneta) com del mateix exoplaneta:

koi_period (Orbital Period): Indica el període orbital del candidat, és a dir, quant temps triga a completar una volta sencera al voltant de la seva estrella amfitriona. Aquest valor es mesura en dies i es calcula observant l'interval de temps entre dos trànsits consecutius.

Justificació: La periodicitat estricta és el requisit número u per considerar un objecte com a candidat. A més, gràcies a la 3a Llei de Kepler, el període ens informa de la distància a l'estrella; això ajuda el model a descartar senyals amb períodes físicament impossibles o que coincideixen amb cicles de soroll instrumental coneguts.

koi_impact (Impact Parameter): Mesura la distància mínima projectada entre el centre del planeta i el centre de l'estrella durant el moment de màxima alineació. El seu funcionament és relatiu al radi estel·lar: un valor de **0** indica un trànsit central, mentre que un valor proper a **1** indica un trànsit rasant.

Justificació: Aquesta variable determina la geometria de l'eclipsi. Els exoplanetes sòlids i ben definits solen tenir valors d'impacte menors a 1. Valors alts (> 1) o molt propers a 1 generen corbes de llum en forma de "V" (en lloc d' $\ddot{U}$), la qual cosa és un indicador molt fort que es tracta d'una estrella binària eclipsant (fals positiu) i no d'un planeta.

koi_duration (Transit Duration): Correspon al temps total, mesurat en hores, que el planeta està davant del disc estel·lar bloquejant-ne la llum. Aquest interval abarca des del moment en què el planeta comença a entrar en el camp de visió (ingrés) fins que en surt completament (egrés).

Justificació: La durada serveix com a control de coherència física. Hi ha una relació matemàtica directa entre com de ràpid es mou un planeta (període) i quant temps triga a creuar l'estrella (durada). Si el model detecta una durada extremadament curta per a un període llarg, pot classificar-ho automàticament com a soroll o un "glitch" del telescopi, ja que no té sentit físic.

koi_depth (Transit Depth): Mesura la disminució de la brillantor de l'estrella durant el trànsit, expressada habitualment en parts per milió (ppm). Indica quina fracció de la llum estel·lar és bloquejada pel cos que passa per davant.

Justificació: És la mesura directa de la grandària relativa entre l'objecte i l'estrella. Aquesta variable és fonamental per al classificador perquè els exoplanetes, en ser molt més petits que les estrelles, provoquen caigudes de llum petites (profunditats baixes). En canvi, si el model detecta una profunditat molt gran (bloqueig de molta llum), és un indicador clar que l'objecte és probablement una altra estrella (sistema binari eclipsant) i no un planeta.

koi_steff (Stellar Effective Temperature): Indica la temperatura de la superfície de l'estrella en graus Kelvin.

Justificació: Aquesta variable permet classificar el tipus espectral de l'estrella (si és una nana vermella, una semblant al Sol o una gegant blava). És necessària per determinar la "Zona d'Habitabilitat" per descartar falsos positius, ja que certs tipus d'estrelles molt calentes o inestables generen soroll que es pot confondre amb planetes.

koi_slogg (Stellar Surface Gravity): Representa el logaritme (base 10) de l'acceleració de la gravetat a la superfície de l'estrella.

Justificació: Serveix principalment per distingir entre una estrella nana (seqüència principal) i una estrella gegant. Això és vital perquè detectar un planeta petit davant d'una estrella gegant és extremadament difícil; per tant, el model utilitza aquesta dada per avaluar la fiabilitat del senyal detectat.

koi_srad (Stellar Radius): És el radi de l'estrella mesurat en unitats de radis solars.

Justificació: És la variable de context més important. La profunditat del trànsit no ens dona la mida absoluta del planeta, sinó la relació de mides $(R_{\text{planeta}}/R_{\text{estrella}})^2$. Sense conèixer el radi de l'estrella (**koi_srad**), és matemàticament impossible calcular el radi real del planeta (**koi_prad**) i saber si estem detectant una Terra o un Júpiter.

koi_prad (Planetary Radius): Indica el radi estimat del planeta candidat, expressat en unitats de radis terrestres ($R_{\oplus}$). Per exemple, un valor de 1 seria la mida de la Terra i un valor d'11 seria la mida de Júpiter.

Justificació: És possiblement la variable discriminatòria més potent del conjunt de dades. Els planetes tenen un límit físic de grandària (aproximadament 1.8 a 2.5 vegades el radi de Júpiter com a màxim). Si el model detecta un valor **koi_prad** excessivament alt (per exemple, 50 o 100 $R_{\oplus}$), pot determinar immediatament que l'objecte no és un planeta, sinó una estrella petita eclipsant una de gran (Fals Positiu).

koi_teq (Equilibrium Temperature): És una estimació de la temperatura superficial del planeta en Kelvin (K). Es calcula modelant el planeta com un cos negre termodinàmic que absorbeix l'energia de l'estrella i la re-irradia.

Justificació: Aquesta variable aporta coherència física al model. Ajuda a validar la relació entre la distància a l'estrella i l'energia rebuda. A més, permet identificar

categories específiques com els "Júpiter Calents" (planetes gegants amb temperatures de milers de graus). Valors físicament impossibles o contradictoris amb l'òrbita poden assenyalar errors instrumentals.

koi_insol (Insolation Flux): Mesura el flux d'insolació, és a dir, la quantitat de radiació electromagnètica que el planeta rep de la seva estrella comparada amb la que la Terra rep del Sol (valors relatius a la Terra).

Justificació: Està estretament lligada a la temperatura però se centra en l'energia rebuda. És útil per al model perquè existeix una correlació física coneguda: els planetes gegants sotmesos a una insolació molt alta tendeixen a inflar-se" (augmentar el seu radi degut a l'agitació tèrmica de l'atmosfera). El model pot aprendre aquesta relació (més insolació → radi lleugerament més gran) per validar candidats reals versus falsos positius que no segueixen aquestes lleis físiques.

3 Exploració de les dades

Per explorar i analitzar les dades utilitzarem Python. Una vegada hem carregat les dades podem estudiar els valors faltants a les observacions.

En aquestes dades trobem que hi han variables amb fins a 363 valors faltants, per tant eliminem aquestes observacions, ja que si les conservem no ens permetran realitzar l'estudi exploratori ni l'anàlisi amb aprenentatge automàtic.

Una vegada eliminats els valors faltants, podem observar la distribució de la variable resposta, que és `koi_disposition`.




Figura 2: Distribució `koi_disposition`

En aquesta trobem que pren 3 valors possibles: 'CONFIRMED', 'FALSE POSITIVE', 'CANDIDATE'. Com hem dit abans eliminarem les observacions amb valor 'CANDIDATE'. Això ens deixarà amb 7015 observacions.

Ara ja podem calcular els estadístics bàsics de les variables explicatives. Obtenim:

	count	mean	std	min	25%	50%	75%	max
koi_fpflag_nt	7015	0.22	0.42	0.00	0.00	0.00	0.00	1.00
koi_fpflag_ss	7015	0.31	0.46	0.00	0.00	0.00	1.00	1.00
koi_fpflag_co	7015	0.26	0.44	0.00	0.00	0.00	1.00	1.00
koi_fpflag_ec	7015	0.16	0.37	0.00	0.00	0.00	0.00	1.00
koi_period	7015	56.57	119.91	0.24	2.20	8.21	31.86	1071.23
koi_impact	7015	0.80	3.67	0.00	0.22	0.58	0.92	100.81
koi_duration	7015	5.92	7.00	0.10	2.56	3.95	6.47	138.54
koi_depth	7015	30619.16	92880.57	0.80	184.50	507.30	2768.40	1.54e+06
koi_prad	7015	129.99	3519.87	0.08	1.52	2.68	25.44	2.00e+05
koi_teq	7015	1148.57	898.39	92.00	559.00	928.00	1496.50	1.47e+04
koi_insol	7015	8451.80	160672.22	0.02	23.07	175.17	1185.89	1.09e+07
koi_steff	7015	5727.70	825.28	2661.00	5320.00	5779.00	6126.00	15896.00
koi_slogg	7015	4.30	0.44	0.05	4.21	4.44	4.54	5.28
koi_srad	7015	1.78	6.20	0.12	0.83	1.00	1.37	229.91
koi_kepmag	7015	14.25	1.40	6.97	13.42	14.50	15.31	20.00

Taula 1: Taula estadístics descriptius variables resposta

A partir de la taula anterior, es poden extreure diverses conclusions fonamentals sobre la distribució i la qualitat de les dades, les quals condicionaran el preprocessament posterior:

L'anàlisi de la taula revela distribucions altament esbiaixades en variables físiques com *koi_insol* o *koi_prad*, on la mitjana supera enormement la mediana a causa de valors atípics extrems. Mentre que variables com les *koi_fpflag* funcionen clarament com a indicadors binaris i mostren una consistència total en el nombre de registres (7015), la disparitat d'escalles és crítica: tenim des de valors petits a *koi_kepmag* fins a milions a *koi_depth*. Aquesta enorme variabilitat de rangs suggereix que serà imprescindible normalitzar o estandarditzar les dades abans d'aplicar qualsevol model predictiu per a evitar biaixos durant l'entrenament.

Observem la distribució d'algunes de les variables no binàries:




Figura 3: Distribució variables predictores




Figura 4: Distribució variables predictores

Veiem que al radi planetari, al període, i a la profunditat de trànsit, ha sigut necessari aplicar una transformació logarítmica, ja que les distribucions són molt esbiaixades amb valors extrems, com ja hem vist a la taula. Mentre que les altres distribucions també veiem que són esbiaixades, però no hi ha valors tan extrems com per necessitar una transformació logarítmica.

Aquesta evidència gràfica valida la necessitat d'estandarditzar les dades per evitar que variables amb magnituds desproporcionades distorsionin l'entrenament del model, ja que hem observat que algunes variables arriben fins valors molt alts mentre que altres tenen una escala molt més reduïda.

Amb l'objectiu d'analitzar possibles relacions lineals entre les variables numèriques, es construeix la matriu de correlacions:






Figura 5: Correlacions entre predictores

S'observa que els indicadors de falsos positius (koi_fpflag) estan moderadament correlacionats entre ells. En canvi, la majoria de variables físiques planetàries mostren una baixa correlació lineal, suggerint que aporten informació independent, a part de dues: la matriu destaca una forta correlació positiva entre el radi planetari (koi_prad) i el paràmetre d'impacte (koi_impact), així com una relació inversa clara entre la gravetat superficial

(koi_slogg) i el radi estel·lar (koi_srad), cosa que té sentit en els dos casos ja que la relació entre aquestes magnituds és total o parcialment determinista, com podem veure als següents gràfics:



(a) Relació entre radi planetari i paràmetre d'impacte



(b) Relació entre radi estel·lar i gravetat a la superfície de l'estrella

L'exploració confirma que, tot i la riquesa de les dades, aquestes presenten alguns problemes per al modelatge: escales extremadament dispars, distribucions amb biaixos severos, i problemes de multicolinealitat (tots aquests representaran un problema dependent del model que s'utilitzi). En conseqüència, al preprocessament pot ser necessari aplicar transformacions logarítmiques i estandardització per estabilitzar la variància, així com gestionar les correlacions detectades i valors extrems (que són els que generen les distribucions esbiaixades).

4 Aplicació d'algorismes d'aprenentatge automàtic

4.1 Algorismes empletats i justificació

Per tal d'abordar la naturalesa multidimensional de les dades obtingudes pel telescopi Kepler, s'ha seguit una metodologia que integra tres dels algorismes més rellevants de l'aprenentatge automàtic supervisat. Aquesta selecció permet capturar des de relacions de proximitat local fins a estructures d'ensamblatge i optimització d'hiperplans, garantint una anàlisi robusta de la frontera de decisió entre els exoplanetes confirmats i els diversos tipus de falsos positius astronòmics.

L'algorisme **K-Nearest Neighbors (K-NN)** es defineix com un mètode d'aprenentatge basat en instàncies que no requereix una fase d'entrenament explícita, sinó que emmagatzema les observacions per classificar noves dades segons la seva similitud en l'espai de característiques. El nucli matemàtic d'aquest procés resideix en el càlcul de la distància euclidiana o norma L_2 entre un vector de prova $\mathbf{x}$ i els vectors d'entrenament $\mathbf{y}$, expressada mitjançant la funció $d(\mathbf{x}, \mathbf{y}) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$. Dins d'aquest esquema, l'hiperparàmetre K actua com un mecanisme de suavitzat on l'elecció d'un valor reduït pot capturar patrons molt fins però augmenta la sensibilitat al soroll, mentre que un K elevat redueix la variància a canvi d'incrementar el biaix del model. Aquesta tècnica resulta d'especial utilitat en astrofísica per identificar si els sistemes planetaris confirmats mostren patrons en els seus paràmetres físics fonamentals.

En un segon nivell de complexitat estructural, s'ha implementat el **Random Forest**

(**RF**), un model d'ensamblatge basat en la combinació d'arbres de decisió mitjançant la tècnica de *Bootstrap Aggregating* o *bagging*. Cada arbre es construeix seleccionant aleatòriament subconjunts de dades i de variables predictores, una estratègia que minimitza la correlació entre els arbres individuals i maximitza la capacitat de generalització. El criteri de divisió a cada node es fonamenta en la reducció de la impuresa de Gini, definida matemàticament com $G = 1 - \sum_{i=1}^C p_i^2$, on p_i representa la proporció d'instàncies de la classe i en un node determinat. En maximitzar el guany d'informació a través de la minimització de G , l'algorisme aconsegueix organitzar les variables segons el seu poder discriminatori, gestionant amb gran eficàcia l'heterogeneïtat i els valors atípics de la missió Kepler sense sobreajustament.

Finalment, el marc metodològic es completa amb l'aplicació de les **Màquines de Suport Vectorial (SVM)**, un enfocament centrat en la cerca de l'hiperplà òptim que maximitzi el marge de separació entre les classes. El problema d'optimització es planteja formalment com la minimització de la funció $\frac{1}{2}\|\mathbf{w}\|^2$ sota un conjunt de restriccions de classificació correcta. Atesa la naturalesa no lineal de moltes interaccions astronòmiques, s'ha optat per l'ús de la funció de base radial (RBF) com a *kernel*, la qual permet projectar les dades originals a un espai de dimensió superior mitjançant la transformació $K(\mathbf{x}, \mathbf{x}') = \exp(-\gamma\|\mathbf{x} - \mathbf{x}'\|^2)$. En aquest context, el paràmetre γ regula l'abast de la influència dels punts d'entrenament, mentre que el paràmetre de regularització C gestiona el compromís entre la maximització del marge i la tolerància a classificacions errònies. Aquesta flexibilitat permet a l'SVM definir fronteres de decisió extremadament precises en entorns de dades altament complexos.

4.2 Mètriques d'avaluació i rigor estadístic

Per avaluar l'eficàcia dels models s'estableix un marc basat en la matriu de confusió, que categoritza les prediccions en veritables positius (TP), negatius (TN), falsos positius (FP) i negatius (FN). A partir d'aquests components, es defineixen mètriques que permeten interpretar el rendiment des de diverses perspectives estadístiques.

L'exactitud ($ACC = \frac{TN+TP}{TN+TP+FP+FN}$) mesura la proporció d'encerts totals sobre el volum de dades. Tot i ser la mesura més intuïtiva, en astrofísica s'ha de considerar amb cautela, ja que davant distribucions de classes asimètriques pot resultar enganyosa en ignorar el rendiment sobre la classe minoritària.

Per corregir aquest biaix s'utilitza el *F1-Score* ($F1 = \frac{2TP}{2TP+FP+FN}$), definit com la mitjana harmònica entre la precisió i l'exhaustivitat. Aquesta mètrica obliga el model a equilibrar la identificació d'exoplanetes reals amb la minimització de falses alarmes, penalitzant els valors extrems per garantir una classificació més robusta de la classe positiva.

D'altra banda, l'Àrea Sota la Corba (AUC) mesura la capacitat de discriminació del classificador a través de tots els llindars de decisió possibles. L'AUC s'obté integrant la taxa de veritables positius ($TPR = \frac{TP}{TP+FN}$) respecte a la de falsos positius ($FPR = \frac{FP}{FP+TN}$), utilitzant la regla del trapezi per a la seva aproximació numèrica:

$$AUC \approx \sum_{i=1}^n \frac{(TPR_{i-1} + TPR_i)}{2} \cdot (FPR_i - FPR_{i-1})$$

Aquesta mètrica és clau en la missió Kepler, ja que avalua la robustesa del model de forma independent al punt de tall escollit.

Finalment, s'incorpora el Coeficient de Correlació de Matthews (*MCC*), l'estàndard més rigorós per a la validació binària en utilitzar tots els quadrants de la matriu de confusió:

$$MCC = \frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$$

Amb un rang entre -1 i $+1$, l'*MCC* és robust davant el desequilibri de classes, garantint que el rendiment reflecteixi fidelment la capacitat predictiva del model tant per confirmar exoplanetes com per descartar falsos positius.

Per tal de realitzar una comparació final objectiva i rigorosa entre els tres algorismes seleccionats, s'ha implementat una estratègia de *K-fold Cross Validation* ($K = 10$) com a mecanisme principal de selecció de models. Aquesta metodologia és fonamental per evitar el 'factor sort' inherent a una única partició de dades, ja que un model podria resultar afavorit per el conjunt de dades de test escollit. Aquest procediment calcula les mètriques per K particions de la base de dades diferents i d'aquesta manera s'introdueix rigor estadístic en aquestes mètriques.

Això ens permet avaluar si hi han diferències significatives en les mètriques dels models. Primer evaluant si les diferències en les mètriques són normals (Shapiro-Wilk) i després utilitzant el test correcte (Wilcoxon o t-test) per evaluar si les diferències són significatives.

4.3 Aplicació dels algoritmes i entrenament dels models amb el conjunt de dades

Per l'entrenament dels models s'ha utilitzat el paquet `SciKitLearn` de Python. Que dona objectes de tots els models que necessitem, una funció per entrenar-los en unes dades i utilitats específiques de cada model. Tot el codi utilitzat és a l'anex.

4.3.1 Normalització: Standard Scaler

Atès que s'ha observat una gran disparitat en les escales de les variables (des de valors unitaris fins a milions en *koi_depth*), s'han normalitzat les dades. Per als models de K-NN i SVM, s'ha utilitzat la classe `StandardScaler`. Aquesta tècnica consisteix en:

- **Càlcul de paràmetres:** Calcula la mitjana (μ) i la desviació típica (σ) exclusivament sobre el conjunt d'entrenament.
- **Transformació Z-score:** Transforma les dades perquè tinguin mitjana 0 i variància 1, assegurant que cap variable domini sobre les altres per la seva magnitud mitjançant l'equació:

$$z = \frac{x - \mu}{\sigma}$$

4.3.2 Estratègia d'ajust d'hiperparàmetres

L'entrenament no s'ha limitat a una configuració única, sinó que s'ha explorat un espai de paràmetres per identificar la combinació òptima per a cada algorisme:

K-NN: S'ha executat un bucle iteratiu provant diferents valors de k (de 1 a 30) per observar com afecta la proximitat dels veïns a la precisió de la classificació.

SVM: S'han avaluat diferents configuracions de *Kernels* (lineal i RBF) i valors del paràmetre de regularització C (1 i 10), a més de variar el coeficient γ per al kernel radial.

Random Forest: S'ha explorat la complexitat de l'arbre variant el nombre d'estimadors (entre 50 i 300) i la profunditat màxima (`max_depth`) per trobar l'equilibri entre capacitat predictiva i generalització.

5 Resultats i interpretació

5.1 Presentació dels resultats obtinguts

Per optimitzar el rendiment de cada model, s'ha realitzat una cerca dels hiperparàmetres que maximitzen les mètriques d'avaluació. Els resultats detallats es presenten a continuació.

5.1.1 K-NN

L'algorisme K-NN es va avaluar amb $k \in \{1, 3, 5, 7, 10, 15, 20, 30\}$, tal com es mostra a la Taula 2.

k	Exactitud	F1	MCC	AUC
1	0.9836	0.9750	0.9629	0.9828
3	0.9857	0.9782	0.9676	0.9893
5	0.9857	0.9781	0.9676	0.9929
7	0.9857	0.9781	0.9676	0.9943
10	0.9843	0.9759	0.9643	0.9951
15	0.9850	0.9770	0.9659	0.9949
20	0.9850	0.9770	0.9659	0.9951
30	0.9850	0.9770	0.9659	0.9940

Taula 2: Resultats de l'algorisme K-NN per a diferents valors de k

L'anàlisi indica que la configuració amb $k = 7$ és la més equilibrada. Tot i que els valors $k = 3$ i $k = 5$ igualen l'exactitud (0.9857) i l'MCC (0.9676), $k = 7$ ofereix una millora en l'AUC (0.9943). Aquest augment suggereix que un veïnatge més ampli incrementa la robustesa davant el soroll astronòmic i evita el sobreajustament observat en $k = 1$. A partir de $k = 10$, l'exactitud s'estabilitza vora el 0.9850; malgrat que $k = 20$ assoleix el màxim AUC (0.9951), la lleugera degradació en exactitud i F1-score confirma $k = 7$ com el punt d'inflexió ideal per capturar les relacions de proximitat de la missió Kepler.

5.1.2 Màquines de Suport Vectorial (SVM)

Es van explorar kernels lineals i radials (RBF), variant $C \in \{1, 10\}$ i $\gamma \in \{0.1, \text{scale}\}$, amb els resultats recollits a la Taula 3.

Kernel	C	γ	Exactitud	F1	MCC	AUC
RBF	1	scale	0.9850	0.9770	0.9659	0.9972
RBF	10	0.1	0.9865	0.9792	0.9692	0.9971
RBF	1	0.1	0.9850	0.9770	0.9659	0.9968
RBF	10	scale	0.9857	0.9781	0.9676	0.9967
Lineal	10	N/A	0.9822	0.9728	0.9596	0.9916
Lineal	1	N/A	0.9822	0.9728	0.9596	0.9900

Taula 3: Resultats de l'algorisme SVM per a diferents configuracions

La configuració RBF amb $C = 10$ i $\gamma = 0.1$ resulta ser la més robusta, dominant en exactitud (0.9865), F1-score (0.9792) i MCC (0.9692). Tot i que la variant amb $C = 1$ i *gamma scale* presenta un AUC marginalment superior (0.9972 vs 0.9971), la millora en la resta de mètriques justifica l'elecció de $C = 10$. La superioritat del kernel RBF sobre el lineal evidencia que la separació entre exoplanetes i falsos positius no és lineal i requereix una transformació a espais de major dimensionalitat per capturar interaccions complexes.

5.1.3 Random Forest

Per a Random Forest es va variar el nombre d'estimadors $n \in \{50, 100, 200, 300\}$ i la profunditat màxima $\text{max depth} \in \{10, 20, 30, \text{NaN}\}$ (on NaN indica profunditat il·limitada). La Taula 4 presenta les millors configuracions:

n estimadors	max depth	Exactitud	F1	MCC	AUC
100	30.0	0.9865	0.9791	0.9691	0.9987
100	NaN	0.9865	0.9791	0.9691	0.9987
50	20.0	0.9865	0.9791	0.9691	0.9986
100	20.0	0.9865	0.9791	0.9691	0.9986
300	NaN	0.9865	0.9791	0.9691	0.9986
300	20.0	0.9865	0.9791	0.9691	0.9986
200	30.0	0.9865	0.9791	0.9691	0.9986
200	NaN	0.9865	0.9791	0.9691	0.9986
300	30.0	0.9865	0.9791	0.9691	0.9986
200	20.0	0.9865	0.9791	0.9691	0.9985
50	30.0	0.9865	0.9791	0.9691	0.9985
50	NaN	0.9865	0.9791	0.9691	0.9985
300	10.0	0.9850	0.9769	0.9659	0.9985
100	10.0	0.9865	0.9791	0.9691	0.9984
200	10.0	0.9857	0.9781	0.9675	0.9984
50	10.0	0.9850	0.9769	0.9659	0.9983

Taula 4: Resultats de l'algorisme Random Forest

El model òptim consta de 100 estimadors i una profunditat de 30.0, assolint el màxim AUC de l'estudi (0.9987). Seguint el principi de parsimònia, s'ha descartat augmentar els estimadors a 200 o 300, ja que no milloren l'exactitud i redueixen lleugerament l'AUC

(0.9986). L'estabilitat observada entre la profunditat 30.0 i la il·limitada (NaN) suggereix que el model assoleix la seva maduresa predictiva sense risc de sobreajustament, consolidant aquesta configuració com la més robusta per a les dades.

5.1.4 K-fold validation

Comparació	Shapiro p	Tipus de Test	Stat p (p -valor)
K-NN vs SVM	0.0899	Paired T-test	0.1115
K-NN vs Random Forest	0.0089	Wilcoxon	0.3945
SVM vs Random Forest	0.2223	Paired T-test	0.7043

Taula 5: Resultats de les proves de significació estadística entre models

S'ha determinat si les diferències observades en la mètrica d'accuracy són estadísticament significatives o si, per contra, poden atribuir-se a la variabilitat inherent de la mostra. En primer lloc, s'ha aplicat el test de Shapiro-Wilk per avaluar la normalitat de les distribucions de rendiment. Tal com es recull a la Taula 5, les comparacions "K-NN vs SVM" $p = 0.0899$ i "SVM vs Random Forest" $p = 0.2223$ presenten distribucions que no s'allunyen significativament de la normalitat ($p > 0.05$), fet que permet l'aplicació del Paired T-test.

En el cas de la comparació "K-NN vs Random Forest", el valor $p = 0.0089$ indica una desviació de la normalitat, motiu pel qual s'ha optat pel test de Wilcoxon (prova no paramètrica). L'anàlisi dels valors p estadístics revela que en cap de les comparacions es troben diferències significatives, ja que tots els valors se situen molt per sobre del llindar crític de $\alpha = 0.05$. Concretament, la comparació entre els dos models amb millor rendiment, l'SVM i el Random Forest, presenta un p -valor de 0.7043, confirmant que ambdós algorismes ofereixen un rendiment estadísticament equivalent per a aquest conjunt de dades.

5.2 Comparació final i selecció del model

En resum, tots els algorismes analitzats presenten un rendiment excepcional, amb una exactitud mitjana que supera el 98,5% en les proves de validació. Malgrat que el K-NN ($k = 7$) és el classificador amb les mètriques més discretes de la sèrie, les diferències entre les tres arquitectures són mínimes.

L'anàlisi de significació estadística realitzada confirma que no existeixen diferències estadísticament significatives entre els models, ja que tots els p -valors obtinguts se situen per sobre del llindar de $\alpha = 0.05$. Concretament, la comparació entre l'SVM i el Random Forest ($p = 0.7043$) demostra una equivalència pràctica en la seva capacitat predictiva.

Atesa aquesta igualtat estadística, es selecciona el Random Forest ($n = 100, d = 30$) com el model definitiu per a aquesta investigació. Aquesta decisió es fonamenta en la seva superioritat en l'AUC 0,9987 i, fonamentalment, en la seva interpretabilitat. Mentre que l'SVM actua com una estructura matemàtica opaca, el Random Forest permet validar que les decisions es basen en paràmetres astronòmics coherents, consolidant-se com l'eina més robusta i explicable per a la detecció d'exoplanetes.

5.3 Interpretació dels resultats en el context del conjunt de dades

Dins del marc del Random Forest, la importància relativa (o *Feature Importance*) és una mètrica que permet quantificar la contribució individual de cada variable predictora a la precisió global del model. Aquesta es calcula mitjançant la reducció mitjana de la impuresa de Gini en cada partició de l'arbre. Les variables que generen nodes més homogenis reben una puntuació més alta, la qual es normalitza perquè el sumatori de totes les importàncies sigui igual a 1, facilitant així la interpretació física del model.




Figura 7: Gràfic d'importància relativa de les variables per al model Random Forest òptim.

L'anàlisi de la Figura 7 revela una jerarquia de decisió altament estructurada. S'observa un predomini absolut dels indicadors de falsos positius (*False Positive Flags*), on *koi_fpflag_nt* destaca com la variable amb més pes predictiu. Aquest resultat és coherent amb la metodologia astronòmica, ja que aquests paràmetres actuen com a filtres diagnòstics que descarten interferències instrumentals o sistemes binaris eclipsants abans d'avaluar la naturalesa de l'objecte.

Pel que fa a les propietats físiques, el radi planetari (*koi_prad*) es consolida com la variable més determinant. La seva alta rellevància es deu al fet que la mida és el factor principal per distingir planetes de nanes marrons o estrelles petites. Altres descriptors com el període orbital (*koi_period*) i la profunditat del trànsit (*koi_depth*) també mostren una contribució significativa. Finalment, és destacable que les característiques de l'estrella amfitriona (*koi_steff*, *koi_srad*) presenten la menor influència relativa, indicant que el model prioritza la senyal del trànsit per sobre del context estel·lar.

6 Conclusions i Treball Futur

6.1 Conclusions generals

Aquest treball ha permès demostrar l'eficàcia de l'aprenentatge automàtic a l'hora de classificació d'objectes astronòmics a partir de les dades recollides pel telescopi espacial Kepler. L'objectiu principal de desenvolupar un classificador capaç de distingir entre exoplanetes confirmats i falsos positius s'ha assolit amb èxit, consolidant una metodologia que permet classificar senyals astronòmics amb un alt grau de fiabilitat. Mitjançant un procés de que ha inclòs la neteja de valors faltants i l'estudi de les distribucions físiques, s'ha garantit que els models d'entrenament treballassin sobre un conjunt de dades representatiu i lliure d'ambigüitats.

L'avaluació comparativa entre els tres algorismes seleccionats —K-Nearest Neighbors, Màquines de Suport Vectorial i Random Forest— revela que tots ells posseeixen una capacitat predictiva excel·lent. Malgrat aquesta igualtat numèrica, el Random Forest ($n = 100$, $depth = 30$) s'ha escollit com el millor model ajustable a les dades.

Un dels assoliments més significatius d'aquest estudi és la capacitat d'interpretar les decisions del model a través de la importància relativa de les variables. L'anàlisi basada en la reducció de la impuresa de Gini ha confirmat que els indicadors de falsos positius instrumentals i el radi planetari `koi_prad` són els factors determinants en la confirmació d'un exoplaneta. El ordre d'importància de les variables és totalment coherent amb els criteris de validació astrofísica de la NASA, la qual cosa valida el model no només des d'una vessant estadística, sinó també des d'una perspectiva física i científica.

En resum, la combinació d'una arquitectura de dades ben estructurada i l'ús d'algorismes d'ensamblatge permet gestionar la complexitat de les dades astronòmiques de forma precisa i transparent.

6.2 Limitacions del treball

Tot i els excel·lents resultats obtinguts pels models de classificació, és necessari reconèixer diverses limitacions que condicionen l'abast de l'estudi i la generalització dels resultats:

L'exclusió de la categoria *CANDIDATE* ha permès obtenir una precisió molt alta en un entorn binari controlat. Tanmateix, en un escenari real d'investigació astrofísica, la gestió dels candidats és la tasca més complexa i crítica, ja que representa el flux de dades que encara requereix validació manual o seguiment per part de la comunitat científica. Per altre banda el model s'ha entrenat utilitzant variables ja processades (com el radi o el flux d'insolació). Això implica que la qualitat de la nostra predicció depèn totalment de la precisió de les mesures prèvies i dels models físics utilitzats pel NASA Exoplanet Archive per calcular aquests paràmetres. No s'ha treballat amb les corbes de llum" (dades brutes de fotometria), on resideix la informació original.

Les dades provenen d'una única missió amb unes característiques instrumentals i un camp de visió específics. Els models podrien presentar un canvi en el rendiment si s'apliquessin a dades d'altres missions (com TESS) que operen en diferents longituds d'ona o amb diferents nivells de soroll instrumental.

Per últim el model té una interpretació subtilment limitada, tot i que el *Random Forest* ens permet saber quines variables són més importants, el model no deixa de ser una caixa

negra estadística que pot detectar correlacions sense que existeixi necessàriament una causalitat física directa en tots els casos.

6.3 Propostes de treball futur

A partir de l'anàlisi realitzada, s'identifiquen diverses línies d'investigació per expandir i millorar la detecció automatitzada d'exoplanetes:

Una evolució natural seria l'ús de Xarxes Neurals Convolucionals (CNN) per analitzar directament les sèries temporals de la brillantor estel·lar (corbes de llum). Això permetria al model aprendre patrons morfològics complexos que els algoritmes clàssics de Machine Learning, basats en variables tabulars, poden passar per alt.

Per altre banda es podria integrar la categoria *CANDIDATE* en un model de classificació multiclasse o desenvolupar un model jeràrquic que primer distingeixi entre senyals reals i soroll, i posteriorment avalui la probabilitat que un candidat sigui realment un exoplaneta.

També es podria investigar la capacitat de generalització del model entrenat amb dades de Kepler aplicant-lo a conjunts de dades de la missió TESS (*Transiting Exoplanet Survey Satellite*). L'ús de tècniques de *Transfer Learning* podria ajudar a adaptar el coneixement adquirit a nous instruments amb pocs exemples etiquetats.

Tot i que s'han explorat diverses configuracions, l'ús de mètodes d'optimització bayesiana podria ajustar amb més precisió els paràmetres dels models SVM i Random Forest per extreure fins a l'últim percentil de rendiment possible.

Per últim podriem estendre l'objectiu del model no només a la detecció, sinó a la classificació del potencial d'habitabilitat (per exemple, mitjançant l'Índex de Similitud amb la Terra o ESI), creuant les dades de classificació amb models climàtics planetaris.

7 Annexos

7.1 Codi utilitzat

```
1 # Carreguem la base de dades
2 df = pd.read_csv('cumulative.csv')
3
4 # Seleccionem només les variables d'interès
5 vars_interes = ["kepoi_name", "koi_disposition", "koi_fpflag_nt", "
    koi_fpflag_ss", "koi_fpflag_co", "koi_fpflag_ec", "koi_period", "
    koi_impact", "koi_duration", "koi_depth", "koi_prad", "koi_teq", "
    koi_insol", "koi_steff", "koi_slogg", "koi_srad", "koi_kepmag"]
6 df = df[vars_interes]
7 df.head()
8 print(df.isnull().sum())
9 df = df.dropna()
10 len(df)
```

Listing 1: Creació DB i estudi valors nuls

```
1 plt.figure(figsize=(8, 5))
2 sns.countplot(x='koi_disposition', data=df, palette='viridis')
3 plt.title('Distribució de les Classes (Target)')
4 plt.show()
```

Listing 2: Gràfic distribució variable resposta

```
1 df = df[df["koi_disposition"] != "CANDIDATE"]
2 desc_stats = df.describe().transpose()
3 display(desc_stats)
```

Listing 3: Càlcul estadístics descriptius

```
1 # Histogrames de variables clau (amb escala logarítmica per veure millor
    els atípics)
2 fig, axes = plt.subplots(1, 3, figsize=(18, 5))
3
4 # Radi del planeta
5 sns.histplot(df['koi_prad'].dropna(), bins=50, ax=axes[0], log_scale=
    True, color='teal')
6 axes[0].set_title('Distribució del Radi Planetari')
7 axes[0].set_xlabel('Log(Radi) (Radis Terrestres)')
8 axes[0].set_ylabel('Nombre')
9
10 # Període orbital
11 sns.histplot(df['koi_period'].dropna(), bins=50, ax=axes[1], log_scale=
    True, color='orange')
12 axes[1].set_title('Distribució del Període Orbital')
13 axes[1].set_xlabel('Log(període) (dies)')
14 axes[1].set_ylabel('Nombre')
15
16 # Profunditat del transit
17 sns.histplot(df['koi_depth'].dropna(), bins=50, ax=axes[2], log_scale=
    True, color='purple')
18 axes[2].set_title('Distribució de la Profunditat del Transit')
19 axes[2].set_xlabel('Log(profunditat) (ppm)')
20 axes[2].set_ylabel('Nombre')
21 plt.show()
```

Listing 4: Histogrames 1

```

1 # Mes Histogrames de variables predictores
2 fig, axes = plt.subplots(1, 3, figsize=(18, 5))
3
4 # Duracio del transit
5 sns.histplot(df['koi_duration'].dropna(), bins=50, ax=axes[0], color='
    teal')
6 axes[0].set_title('Distribucio duracio transit')
7 axes[0].set_xlabel('Duration (hores)')
8 axes[0].set_yscale('log')
9 axes[0].set_ylabel('Log(Nombre)')
10
11 # Temperatura de la estrella
12 sns.histplot(df['koi_steff'].dropna(), bins=50, ax=axes[1], color='
    orange')
13 axes[1].set_title('Distribucio temperatura estrella')
14 axes[1].set_xlabel('Temperatura (Kelvin)')
15 axes[1].set_ylabel('Nombre')
16
17 # Estimacio temperatura del planeta
18 sns.histplot(df['koi_teq'].dropna(), bins=50, ax=axes[2], color='purple'
    )
19 axes[2].set_title('Distribucio temperatura planeta (estimacio)')
20 axes[2].set_xlabel('Temperatura (Kelvin)')
21 axes[2].set_ylabel('Nombre')
22 plt.show()

```

Listing 5: Histogrames 2

```

1 # Correlacions
2 plt.figure(figsize=(12, 10))
3 # Seleccioem nomes numeriques per la matriu
4 numeric_df = df.select_dtypes(include=['float64', 'int64'])
5 sns.heatmap(numeric_df.corr(), cmap='coolwarm', annot=True)
6 plt.title('Matriu de Correlacio')
7 plt.show()

```

Listing 6: Gràfic correlacions

```

1 import matplotlib.pyplot as plt
2 import seaborn as sns
3
4 plt.figure(figsize=(10, 6))
5
6 # Creacio del diagrama de dispersio (Scatter Plot)
7 sns.scatterplot(
8     data=df,
9     x='koi_impact',
10    y='koi_prad',
11    hue='koi_disposition',
12    style='koi_disposition',
13    palette='Set1',
14    alpha=0.6
15 )
16
17 plt.title('Relacio entre Radi Planetari i Parametre d\'Impacte')

```

```

18 plt.xlabel('Parametre d\'Impacte (Unitats de Radi Estelar)')
19 plt.ylabel('Radi Planetari (Radis Terrestres)')
20
21 # Apliquem escala logaritmica a koi_prad per gestionar valors atipics
22 plt.xscale('log')
23 plt.yscale('log')
24 plt.grid(True, linestyle='--', alpha=0.5)
25
26 plt.legend(title='Disposicio del KOI')
27 plt.show()

```

Listing 7: Grafic Radi planetari-parametre d'impacte

```

1 import matplotlib.pyplot as plt
2 import seaborn as sns
3
4 plt.figure(figsize=(10, 6))
5
6 # Creacio del diagrama de dispersio (Scatter Plot)
7 sns.scatterplot(
8     data=df,
9     x='koi_slogg',
10    y='koi_srad',
11    hue='koi_disposition',
12    style='koi_disposition',
13    palette='Set1',
14    alpha=0.6
15 )
16
17 plt.title('Relacio entre Radi estelar (koi_srad) i Gravetat a la
18          superfcie de l\'estrella (koi_slogg)')
19 plt.xlabel('Gravetat (Log base 10 de l\'acceleracio)')
20 plt.ylabel('Radi Estelar (Radis Solars)')
21
22 plt.grid(True, linestyle='--', alpha=0.5)
23
24 plt.legend(title='Disposicio del KOI')
25 plt.show()

```

Listing 8: Gràfic radi estelar i gravetat estelar

```

1 from sklearn.metrics import accuracy_score, f1_score, roc_auc_score,
2   matthews_corrcoef
3
4 def metriques(y_true, y_pred, y_prob):
5     return {
6         'Accuracy': accuracy_score(y_true, y_pred),
7         'F1 Score': f1_score(y_true, y_pred),
8         'MCC': matthews_corrcoef(y_true, y_pred),
9         'AUC': roc_auc_score(y_true, y_prob)
10    }

```

Listing 9: "Funció per càlcul de mètriques"

```

1 # Eines de preprocessament i divisi
2 from sklearn.model_selection import train_test_split
3 from sklearn.preprocessing import StandardScaler
4

```

```

5 # Model K-NN
6 from sklearn.neighbors import KNeighborsClassifier
7
8 # Preparacio de les dades
9 X = df.drop(columns=['kepoi_name', 'koi_disposition'])
10 y = df['koi_disposition'].apply(lambda x: 1 if x == 'CONFIRMED' else 0)
11
12 # Split train-test (80-20)
13 X_train, X_test, y_train, y_test = train_test_split(
14     X, y, test_size=0.2, random_state=123, stratify=y
15 )
16
17 k_val = [1, 3, 5, 7, 10, 15, 20, 30]
18
19 results = {
20     'k': [],
21     'acc': [],
22     'f1': [],
23     'mcc': [],
24     'auc': [],
25 }
26
27 # Normalitzar les dades
28 scaler = StandardScaler()
29 X_train_scaled = scaler.fit_transform(X_train)
30 X_test_scaled = scaler.transform(X_test)
31
32 # Avaluacio del model
33 for k in k_val:
34     # Entrenar model
35     knn = KNeighborsClassifier(n_neighbors=k)
36     knn.fit(X_train_scaled, y_train)
37
38     # Predecir
39     y_pred = knn.predict(X_test_scaled)
40     y_pred_proba = knn.predict_proba(X_test_scaled)[: , 1]
41
42     # Calcular metriques
43     met = metriques(y_test, y_pred, y_pred_proba)
44
45     # Desar resultats
46     results['k'].append(k)
47     results['acc'].append(met['Accuracy'])
48     results['f1'].append(met['F1 Score'])
49     results['mcc'].append(met['MCC'])
50     results['auc'].append(met['AUC'])
51
52 results = pd.DataFrame(results)
53 print(results)

```

Listing 10: Algorisme K-NN

```

1 from sklearn.svm import SVC
2
3 # Preparacio de les dades
4 X = df.drop(columns=['kepoi_name', 'koi_disposition'])
5 y = df['koi_disposition'].apply(lambda x: 1 if x == 'CONFIRMED' else 0)
6

```

```

7 # Split train-test (80-20)
8 X_train, X_test, y_train, y_test = train_test_split(
9     X, y, test_size=0.2, random_state=123, stratify=y
10 )
11
12 results = {
13     'Config': [],
14     'kernel': [],
15     'C': [],
16     'gamma': [],
17     'acc': [],
18     'f1': [],
19     'mcc': [],
20     'auc': [],
21 }
22
23 # Normalitzar les dades
24 scaler = StandardScaler()
25 X_train_scaled = scaler.fit_transform(X_train)
26 X_val_scaled = scaler.transform(X_test)
27
28 configs_svm = [
29     {'C': 1, 'kernel': 'linear'},
30     {'C': 10, 'kernel': 'linear'},
31     {'C': 1, 'kernel': 'rbf', 'gamma': 'scale'},
32     {'C': 10, 'kernel': 'rbf', 'gamma': 'scale'},
33     {'C': 1, 'kernel': 'rbf', 'gamma': 0.1},
34     {'C': 10, 'kernel': 'rbf', 'gamma': 0.1},
35 ]
36
37 # Avaluacio del model
38 for config in configs_svm:
39     svm = SVC(**config, random_state=123, probability=True)
40     svm.fit(X_train_scaled, y_train)
41
42     y_pred_val = svm.predict(X_val_scaled)
43     y_pred_proba_val = svm.predict_proba(X_val_scaled)[: , 1]
44
45     met = metriques(y_test, y_pred_val, y_pred_proba_val)
46
47     results['Config'].append(f"C{config['C']}_{config['kernel']}_g:{
48 config.get('gamma', 'N/A')}")
49     results['kernel'].append(config['kernel'])
50     results['C'].append(config['C'])
51     results['gamma'].append(config.get('gamma', 'N/A'))
52     results['acc'].append(round(met['Accuracy'], 4))
53     results['f1'].append(round(met['F1 Score'], 4))
54     results['mcc'].append(round(met['MCC'], 4))
55     results['auc'].append(round(met['AUC'], 4))
56
57 # Convertir a DataFrame
58 results_df = pd.DataFrame(results)
59 results_df = results_df.sort_values(by='auc', ascending=False)
60 print(results_df.to_string(index=False))

```

Listing 11: Algorisme SVM

```

1 from sklearn.ensemble import RandomForestClassifier

```

```

2
3 X = df.drop(columns=['kepoi_name', 'koi_disposition'])
4 y = df['koi_disposition'].apply(lambda x: 1 if x == 'CONFIRMED' else 0)
5
6 # Split train-test (80-20)
7 X_train, X_test, y_train, y_test = train_test_split(
8     X, y, test_size=0.2, random_state=123, stratify=y
9 )
10
11 n1 = [50, 100, 200, 300]
12 max_depth = [None, 10, 20, 30]
13 results = []
14
15 for n in n1:
16     for md in max_depth:
17         rf = RandomForestClassifier(
18             n_estimators=n,
19             max_depth=md,
20             random_state=123,
21         )
22
23         rf.fit(X_train, y_train)
24
25         y_pred = rf.predict(X_test)
26         y_pred_proba = rf.predict_proba(X_test)[:, 1]
27
28         met = metriques(y_test, y_pred, y_pred_proba)
29
30         results.append({
31             'n_estimators': n,
32             'max_depth': md,
33             'accuracy': round(met['Accuracy'], 4),
34             'f1': round(met['F1 Score'], 4),
35             'mcc': round(met['MCC'], 4),
36             'auc': round(met['AUC'], 4)
37         })
38
39 results_df = pd.DataFrame(results)
40
41 # Ordenar per AUC
42 results_df_sorted = results_df.sort_values('auc', ascending=False)
43 print(results_df_sorted)
44
45 # Millor configuraci
46 best_config = results_df_sorted.iloc[0]
47 print("\nMejor configuracion:")
48 print(best_config)

```

Listing 12: Algorisme Random Forest

```

1 best_rf = RandomForestClassifier(n_estimators=100, max_depth=30,
2     random_state=123)
3
4 best_rf.fit(X_train, y_train)
5
6 importances = best_rf.feature_importances_
7 feature_names = X.columns
8 feature_importance_df = pd.DataFrame({'Feature': feature_names, '
9     Importance': importances})

```

```

7
8 feature_importance_df = feature_importance_df.sort_values(by='Importance', ascending=False)
9
10 import seaborn as sns
11 import matplotlib.pyplot as plt
12
13 plt.figure(figsize=(10, 6))
14 sns.barplot(x='Importance', y='Feature', data=feature_importance_df, palette='viridis')
15 plt.title('Importància de les Variables - Random Forest')
16 plt.xlabel('Importància relativa')
17 plt.ylabel('Variable (KOI parameter)')
18 plt.show()

```

Listing 13: "Gràfic importància variables"

```

1 from scipy import stats
2 from sklearn.model_selection import KFold, cross_val_score
3 from sklearn.pipeline import Pipeline
4 from sklearn.preprocessing import StandardScaler
5 import itertools
6
7 models = {
8     'K-NN': Pipeline([('scaler', StandardScaler()), ('knn',
9     KNeighborsClassifier(n_neighbors=7))]),
10     'SVM': Pipeline([('scaler', StandardScaler()), ('svm', SVC(kernel='rbf', C=10, gamma=0.1, probability=True))]),
11     'Random Forest': RandomForestClassifier(n_estimators=100, max_depth=30, random_state=123)
12 }
13
14 # Configuraci del Cross-Validation (10 folds)
15 kf = KFold(n_splits=10, shuffle=True, random_state=123)
16
17 # Obtenci dels accuracy
18 cv_scores = {}
19 for name, model in models.items():
20     scores = cross_val_score(model, X, y, cv=kf, scoring='accuracy')
21     cv_scores[name] = scores
22
23 results = []
24 comparacions = list(itertools.combinations(models.keys(), 2))
25
26 for m1, m2 in comparacions:
27     # C lcul de la difer ncia
28     diff = cv_scores[m1] - cv_scores[m2]
29
30     # Test de normalitat (Shapiro-Wilk) sobre les difer ncies
31     shapiro_p = stats.shapiro(diff).pvalue
32
33     # Elecci del test segons la normalitat (alfa = 0.05)
34     if shapiro_p > 0.05:
35         test_name = "t-test"
36         t_stat, p_val = stats.ttest_rel(cv_scores[m1], cv_scores[m2])
37     else:
38         test_name = "Wilcoxon"
39         stat, p_val = stats.wilcoxon(cv_scores[m1], cv_scores[m2])

```

```

39
40     results.append({
41         'Comparaci ': f"{m1} vs {m2}",
42         'Shapiro p': round(shapiro_p, 4),
43         'Test': test_name,
44         'p-valor Sig.': round(p_val, 4),
45     })
46
47 df_stats = pd.DataFrame(results)
48 print(df_stats)

```

Listing 14: "k-fold cross validation"

8 Bibliografia i Webgrafia

Referències

- [1] NASA Exoplanet Archive, “Kepler Candidate Table Columns,” https://exoplanetarchive.ipac.caltech.edu/docs/API_kepcandidate_columns.html, 2026. [Accedido: 12-01-2026].
- [2] NASA, “Exoplanetas,” <https://ciencia.nasa.gov/universo/exoplanetas/>, 2026. [Accedido: 12-01-2026]
- [3] NASA Exoplanet Archive. (2024). *Kepler Objects of Interest (KOI) Documentation*. Caltech/IPAC. Recuperat de: https://exoplanetarchive.ipac.caltech.edu/docs/data_sets.html
- [4] Shallue, C. J., i Vanderburg, A. (2018). *Identifying Exoplanets with Deep Learning: A Convolutional Neural Network for Classifying Kepler Space Telescope Light Curves*. The Astronomical Journal, 155(2), 94. <https://doi.org/10.3847/1538-3881/aa9e09>
- [5] NASA. (2023). *Kepler and K2 Science Center: Data Analysis Pipeline*. NASA Ames Research Center. Recuperat de: <https://keplerscience.arc.nasa.gov/pipeline.html>
- [6] Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, 12, 2825-2830.
- [7] NASA. (2024). *Transiting Exoplanet Survey Satellite (TESS) Mission*. Science Mission Directorate. Recuperat de: <https://science.nasa.gov/mission/tess/>
- [8] Thompson, S. E., et al. (2018). *Planetary Candidates Observed by Kepler. VIII. Data Release 25*. The Astrophysical Journal Supplement Series, 235(2).
- [9] Snoek, J., Larochelle, H., i Adams, R. P. (2012). *Practical Bayesian Optimization of Machine Learning Algorithms*. Advances in Neural Information Processing Systems (NIPS).
- [10] Schulze-Makuch, D., et al. (2011). *A Two-Tiered Classification System for Habitability of Exoplanets*. Astrobiology, 11(10), 1041-1052.