

# Document Base de dades

Grup 12

Abril 2026

## 1 Context de les dades

League of Legends (LoL) és un videojoc d'estratègia i acció competitiva per equips (gènere MOBA) que s'ha consolidat com un dels títols més influents en l'àmbit dels eSports a escala mundial. En cada partida, dos equips de cinc jugadors s'enfronten en un mapa tancat amb l'objectiu final de destruir l'estructura principal de la base enemiga, coneguda com a Nexe. La complexitat del joc resideix en la interacció constant entre la presa de decisions estratègiques, el control d'objectius neutrals (com dracs o torres) i l'acumulació de recursos en temps real.

La base de dades utilitzada per a aquest estudi s'ha extret de Kaggle, una plataforma de referència en ciència de dades que allotja conjunts de dades d'alta qualitat. Aquest dataset en particular recull informació detallada de milers de partides de nivell competitiu —generalment de rangs alts com Diamant o Màster— obtingudes mitjançant l'API oficial de Riot Games.

L'interès d'aquest conjunt de dades per a l'anàlisi mitjançant xarxes bayesianes rau en la naturalesa inherentment probabilística del joc. A diferència d'altres sistemes lineals, en el LoL molts esdeveniments estan encadenats: la consecució d'un avantatge primerenc (com la "primera sang") pot augmentar la probabilitat de capturar objectius posteriors, els quals, al seu torn, influeixen en la probabilitat final de victòria. La base de dades ens ofereix una instantània d'aquestes correlacions, permetent-nos modelitzar com la variació en determinats factors del joc primerenc condiciona el desenllaç de la partida.

## 2 Variables


Com que el joc es juga en dos equips, les variables estan dividides en aquests dos bàndols: Blue (blau) i Red (vermell). Totes les variables, doncs, estan assignades a un dels dos equips i recullen informació sobre les estadístiques respectives al minut 10:00 de la partida.

**blueWins: (binària [0,1])**


És la variable objectiu. El model ha d'estimar la probabilitat que aquesta variable sigui 1 o 0 tenint en compte totes les altres. Com que només pot guanyar un equip, predir un 1 en aquesta variable és equivalent a predir un 0 en la variable **redWins**.

### **blueWardsPlaced i redWardsPlaced:**

Recullen el nombre de "Wards" (sentinelles) que han sigut col·locats en el mapa per cadascun dels equips. Els "Wards" són una eina dins del joc que et permet tenir visió d'una part del mapa on normalment no en tindries; per això és una variable que pot tenir molt de pes a l'hora de predir la victòria.



(a) Histograma de **blueWardsPlaced**



(b) Histograma de **redWardsPlaced**

Podem observar que la distribució d'aquestes dues variables presenta el creuament de dues poblacions, generant una distribució bimodal. Com que és l'única variable de la base de dades amb aquesta característica, s'ha decidit provar dues maneres de discretització: per quantils i de manera manual (per intentar captar les dues corbes que presenta la distribució). Es realitzaran dos models, un amb cada mètode de discretització, i el que millors mètriques presenti serà el definitiu.

### **blueWardsDestroyed i redWardsDestroyed:**

Aquestes variables recullen la informació del nombre de "Wards" que cada equip ha trencat. Els jugadors de cada equip poden trencar els "Wards" que l'altre equip col·loca en el mapa. Aquesta variable està discretitzada pel mètode de quantils amb  $n = 6$ .

### **blueFirstBlood: (binària [0,1])**

Pren el valor d'1 si l'equip blau fa la "primera sang", és a dir, si efectua la primera eliminació de la partida, i 0 en cas contrari. Aquesta variable és complementària a la variable **redFirstBlood**; per tant, aquesta última no s'inclourà en el model per evitar redundàncies.

### **redKills i blueKills:**

El nombre total d'eliminacions aconseguides per cada equip. Aquestes variables estan discretitzades pel mètode de quantils amb  $n = 6$ .

### **redDeaths i blueDeaths:**

El nombre total de morts de cada equip. A priori, sembla que aquesta variable sigui complementària a **redKills**, però existeixen altres maneres de morir en la partida (com ara per

torres o monstres neutrals). Aquestes variables estan discretitzades pel mètode de quantils amb  $n = 6$ .

#### **redAssists i blueAssists:**

El nombre total d'assistències de cada equip. Compta com a assistència qualsevol acció que ajudi un aliat a eliminar algú de l'equip contrari. Aquestes variables estan discretitzades pel mètode de quantils amb  $n = 6$ .

#### **redDragons i blueDragons:**

Recullen el nombre de dracs eliminats per cada equip. Els dracs proporcionen estadístiques permanents per a l'equip que els elimina, i per això són vitals a l'hora de guanyar la partida. Com que les dades pertanyen al minut 10:00 de la partida, aquesta variable només pot prendre el valor de 0 o 1, ja que no és possible que apareguin més dracs abans d'aquest temps. Tampoc són complementàries, ja que es pot donar el cas en què cap equip elimini el drac.

#### **redHeralds i blueHeralds:**

Recullen el nombre de "Heralds" (Heralds de l'Esquerra) eliminats per cada equip. Els "Heralds" són una eina dins del joc que et permet avançar pel mapa ajudant a destruir les torres rivals. Aquesta variable només pren el valor 0 o 1, ja que no hi ha més d'un "Herald" disponible en aquest minut de la partida.

#### **redTowersDestroyed i blueTowersDestroyed:**

Aquesta variable recull el nombre de torres destruïdes per cada equip. Destruir una torre et permet guanyar control del mapa amb l'objectiu d'arribar al nexa enemic, de manera que aquesta variable tindrà un paper important en el model. Al minut 10:00, el més probable és haver destruït com a molt 1 torre; per tant, aquesta variable es discretitzarà en 3 grups: 0 torres, 1 torre i 2 o més torres.

#### **redTotalMinionsKilled i blueTotalMinionsKilled:**

Recullen el nombre total de "minions" (súbdits) que l'equip ha eliminat. Els "minions" apareixen en 3 zones (línies) del mapa, i 3 persones de cada equip són les encarregades d'eliminar-los per obtenir recursos fonamentals com ara or i experiència. Aquesta variable s'ha discretitzat amb el mètode de quantils amb  $n = 6$ .

#### **redTotalJungleMinionsKilled i blueTotalJungleMinionsKilled:**

Recullen el nombre total de "Jungle minions" (monstres de la jungla) eliminats. Aquests monstres apareixen a la zona de la jungla i només una persona de cada equip és l'encarregada d'eliminar-los per tal d'aconseguir-ne l'or i l'experiència. Aquesta variable s'ha discretitzat amb el mètode de quantils amb  $n = 6$ .

### **redTotalGold i blueTotalGold:**

Recullen la quantitat d'or que l'equip ha acumulat fins al minut 10:00. L'or és un factor decisiu per aconseguir la victòria, ja que permet comprar objectes dins del joc que et donen un avantatge estadístic directe sobre el rival. L'or s'aconsegueix de moltes maneres: amb eliminacions, dracs, torres, "Wards" trencats, "minions" eliminats, etc. Aquesta variable s'ha discretitzat pel mètode de quantils amb  $n = 6$ .

### **redTotalExperience i blueTotalExperience:**

Recullen l'experiència total de l'equip. L'experiència serveix per pujar de nivell (fins a un màxim de 18). Cada vegada que s'augmenta de nivell, es pot millorar una habilitat del personatge i les seves estadístiques base també pugen; per tant, l'experiència és un factor molt decisiu a l'hora de guanyar la partida. L'experiència s'obté eliminant "minions" o estant a prop mentre són eliminats. Aquesta variable s'ha discretitzat amb el mètode de quantils amb  $n = 6$ .

## **3 Pretractament i neteja de dades**

Abans de procedir a l'anàlisi, s'ha dut a terme una fase de depuració. S'ha confirmat que el dataset no presentava cap valor nul, per la qual cosa l'única intervenció necessària ha estat el tractament d'observacions anòmales (*outliers*).

Les variables de visió, `blueWardsPlaced` i `redWardsPlaced`, s'han identificat com els millors indicadors d'aquests valors extrems. En alguns casos, el nombre de sentinelles col·locats era tan elevat que resultava pràcticament impossible d'executar en els primers 10 minuts de partida. Per netejar la mostra, s'han descartat les observacions situades per sota del quantil 0.025 i per sobre del quantil 0.975 d'aquestes variables.

Com a resultat, el dataset ha passat de 9.879 a 9.131 observacions. Aquest filtratge garanteix que el model es basi en partides amb un comportament estàndard, evitant distorsions en les distribucions.