

Informe de Resultats: Predicció de Victòria al League of Legends

Modelització de Dades Complexes

Autors:

Pol Ortiz (1706755)

Pau Verdejo (1687736)

Professora:

Rosario Delgado de la Torre

Data: Juny 2026

Facultat de Ciències
Universitat Autònoma de Barcelona

Índex

1	Context del treball i natura de les dades	2
1.1	League of legends	2
2	Preprocessing i Neteja de la Base de Dades	2
2.1	Tractament d'Outliers	2
2.2	Estratègia de Discretització	3
2.3	Variables Binàries	3
3	Construcció dels Models	3
3.1	Metodologia	3
3.2	Arquitectures de Xarxa	4
3.3	Selecció de Variables: Markov Blanket	4
4	Validació i Comparativa dels Models	4
4.1	Procés de Validació	4
4.2	Mètriques d'Avaluació	5
4.3	Resultats de la Validació (10-fold CV)	5
5	Tests Estadístics i Correcció per Comparació Múltiple	5
5.1	Metodologia	5
5.2	Normalitat (Shapiro-Wilk)	6
5.3	Tests per Parells — Accuracy	6
5.4	Tests per Parells — AUC	6
5.5	Tests per Parells — Brier Score (Mètrica Decisiva)	7
5.6	Interpretació dels Tests	7
6	Model Final i Casos Representatius	7
6.1	Cas 1: Equip Blau Dominant (Snowball)	7
6.2	Cas 2: Bon Farm sense Objectius	8
6.3	Cas 3: Equip Blau en Desavantatge	8
6.4	Cas 4: Avantatge Parcial (Drac, Or Igualat)	8
7	Conclusions	9
7.1	Selecció del Model Final: ANB_MB	9
7.2	Predictors Clau	9
7.3	Limitacions del Model	9
7.4	Propostes de Millora	9
7.5	Reflexió sobre l'ús de la Intel·ligència Artificial	10

1 Context del treball i natura de les dades

1.1 League of legends

Les dades emprades per la realització dels models provenen d'un joc d'ordinador anomenat League of Legends (LOL). Aquest joc es un dels més "fanbase", acumulant millions de jugadors arreu del mon. La natura del joc en si es molt complexa porque hi han molts factors dins del propi joc que dicataminen el transcurs de la partida, per això al llarg dels anys s'han anat desenvolupant diferents models i algoritmes d'optimització per màximitzar la probabilitat de victòria. D'aquí prove la nostra motivació per crear un clasificador bayèsia que pugui captar la natura del joc i a més relacionar les variables importants amb la probabilitat de victòria per poder crear estratègies que màximitzin aquesta.

El LLOL"es un joc on 2 equips conformats per 5 jugadors han d'aconseguir diferents recursos per poder trencar el inhibidor del equip enemic. El inhibidor es una estructura que es troba protegida en la base de cadascun dels equips, per arribar a trencar aquesta estructura s'han de trencat una serie de torres que bloquejen el camí a aquesta, el primer equip en trencar el inhibidor enemic guanya la partida.

Per poder trencar el inhibidor enemic has de ser més "fort" que el enemic, es a dir les teves estadístiques dins del joc han de ser superiors al las del teu enemic, la millora d'aquestes estadístiques s'aconsegueix mitjançant 3 mètodes diferents:

- Or: per aconseguir or pots eliminar enemics o eliminar minions (cs).
- Nivell d'experiencia: es pot aconseguir eliminant minions i eliminants objectius neutrals.
- Obtenció directa: Obtens estadístiques directament eliminants els objectius neutrals: Dracs i heraldo.

El control del terreny de joc o millor dit control del mapa es molt impotant a l'hora de prendre decisions, els diferents indrets del mapa es ponden controlar posant una mini-estructura anomenada "ward" que dona visió en el radi que es posa.

2 Preprocessing i Neteja de la Base de Dades

En aquesta secció es detallen les transformacions aplicades al *dataset* original (`ranked_10min.csv`, $N = 9.879$ partides) abans de la modelització.

2.1 Tractament d'Outliers

S'ha identificat que les variables de visió (`blueWardsPlaced` i `redWardsPlaced`) presentaven valors anòmals que no corresponen a una dinàmica de joc estàndard. Mitjançant el filtratge per quantils (0.025 i 0.975):

- **Mida inicial:** 9.879 observacions.
- **Mida final:** 9.131 observacions.

- **Justificació:** S'ha eliminat el 5,0% de la mostra corresponent a soroll estadístic i partides atípiques (bots, afk, etc.).

2.2 Estratègia de Discretització

Les xarxes bayesianes requereixen variables discretes. S'han aplicat tres estratègies complementàries:

- **Quantils** ($n = 6$): Aplicat a les variables contínues generals (Or, Experiència, Kills, Morts, Assistències, Minions, Wards Destroyed), garantint categories equilibrades i reduint el risc de paràmetres mal estimats a les taules de probabilitat condicional (CPT).
- **Discretització manual de Torres:** Tres grups lògics basats en el joc: $\{0 \text{ torres}, 1 \text{ torre}, \geq 2 \text{ torres}\}$.
- **Quantils vs manual:** Aplicat a `blueWardsPlaced` i `redWardsPlaced`, per captar l'estructura real del les dades sense degut a la bimodalitat d'aquestes.

Descart de la Discretització Manual per a Wards

La discretització manual no va produir cap millora estadísticament significativa respecte al mètode dels quantils en cap de les mètriques considerades (Accuracy, AUC, Brier Score). A més, va generar categories amb freqüències molt desequilibrades, cosa que augmenta la variança dels estimadors de les CPT. Per tant, s'ha descartat definitivament la discretització manual i s'ha optat per quantils, que combina coherència estadística amb una la eficiència dels estimadors.

2.3 Variables Binàries

Les variables `blueWins`, `blueFirstBlood`, `blueDragons`, `blueHeralds`, `redDragons` i `redHeralds` ja eren binàries $\{0, 1\}$ al *dataset* original i es mantenen com a tals.

3 Construcció dels Models

3.1 Metodologia

El League of Legends presenta relacions causals molt fortes entre variables ($\text{kills} \rightarrow \text{or}$, $\text{or} \rightarrow \text{torres}$, etc.), de manera que la construcció del model ha d'equilibrar fidelitat causal i parsimònia. S'han considerat quatre models organitzats en dues dimensions:

- **Arquitectura:** Naive Bayes (NB) vs. Augmented Naive Bayes (ANB).
- **Conjunt de variables:** Totes les variables (*Full*) vs. les variables del Markov Blanket (MB).

Els quatre models resultants són:

1. **NB_Full** — Naive Bayes amb totes les variables.
2. **ANB_Full** — Augmented Naive Bayes amb totes les variables.
3. **NB_MB** — Naive Bayes amb les variables del Markov Blanket.
4. **ANB_MB** — Augmented Naive Bayes amb les variables del Markov Blanket.

3.2 Arquitectures de Xarxa

Naive Bayes (Tipus Diagnosi). La variable objectiu (**blueWins**) actua com a node pare de totes les variables predictores. S'assumeix independència condicional entre predictors donada la classe. És el model de referència (*baseline*), restrictiu però robust i molt interpretable.

Augmented Naive Bayes (ANB). Es parteix dels arcs obligatoris del NB i s'empra l'algoritme de Hill-Climbing (HC) per aprendre arcs addicionals entre predictors. Això permet captar sinergies lògiques del joc: per exemple, que **kills** influencii **TotalGold** o que l'experiència i l'or estiguin correlacionats positivament. L'estructura resultant és un *Directed Acyclic Graph* (DAG) híbrid.

3.3 Selecció de Variables: Markov Blanket

Per aplicar el principi de parsimònia, s'ha identificat el Markov Blanket (MB) de **blueWins** com el conjunt mínim de variables que el fan condicionalment independent de la resta. El procediment és el següent:

1. S'aplica una validació creuada de 15 folds sobre el *dataset* complet.
2. Per a cada fold, s'aprèn un DAG lliure (sense restriccions) amb HC.
3. S'extreu el MB de **blueWins** en cada DAG.
4. Les variables que apareixen en almenys 2 dels 15 folds s'inclouen al MB final.

El MB final conté **10 variables**:

```
blueDragons, blueTotalGold_disc, blueTotalJungleMinionsKilled_disc, redHeralds,
redTowersDestroyed_disc, blueDeaths_disc, redWardsDestroyed_disc,
redTotalExperience_disc, blueTotalExperience_disc, blueTotalMinionsKilled_disc
```

4 Validació i Comparativa dels Models

4.1 Procés de Validació

Tots els models s'han validat amb una validació creuada estratificada de **10 folds**. Per a cada fold, s'han calculat les probabilitats predites via inferència exacta (Junction Tree, paquet **gRain**) i s'han acumulat per calcular les mètriques globals.

4.2 Mètriques d'Avaluació

- **Accuracy:** $\frac{TP+TN}{N}$. Proporció global d'encerts.
- **AUC-ROC:** Capacitat discriminant del model, independent del llindar. Un valor de 1 indica model perfecte; 0.5 és atzar.
- **Brier Score:** $\frac{1}{N} \sum_i (p_i - y_i)^2$. Mesura la cal·libració de les probabilitats; com més baix, millor.
- **F1-Score:** Mitjana harmònica de precisió i *recall*.
- **BIC:** Penalitza la complexitat estructural (nombre d'arcs) per evitar sobreajustament.
- **Log-Likelihood:** Versemblança de les dades donat el model.
- **Nombre d'arcs:** Indicador de complexitat i interpretabilitat.

4.3 Resultats de la Validació (10-fold CV)

Taula 1: Comparativa de rendiment dels quatre models (10-fold CV).

Model	Acc. (%)	AUC	Brier	F1	Arcs	BIC	LogLik
NB_Full	72.38	0.7993	0.2251	0.7237	24	-292,587.9	-291,744.6
ANB_Full	70.28	0.7823	0.1985	0.7048	49	-239,752.4	-233,913.0
NB_MB	71.99	0.7964	0.2028	0.7217	10	-126,733.5	-126,382.5
ANB_MB *	71.75	0.7938	0.1886	0.7170	18	-122,425.3	-120,825.3

★ *Model seleccionat.*

5 Tests Estadístics i Correcció per Comparació Múltiple

5.1 Metodologia

Per comparar rigorosament els quatre models en les mètriques Accuracy, AUC i Brier Score es segueix el procediment següent:

1. **Test de Shapiro-Wilk (normalitat):** S'aplica sobre els 10 valors per fold de cada model i mètrica. Si $p > 0.05$ s'accepta normalitat.
2. **Test per parells:** Si ambdós models passen la normalitat, s'aplica el *Paired t-test* unilateral; altrament, el *test de Wilcoxon aparellat* unilateral.
3. **Correcció de Holm-Bonferroni:** Amb 4 models es generen $\binom{4}{2} = 6$ parells per mètrica, i per tant 18 comparacions en total. Per controlar la taxa d'error de tipus I, s'aplica la correcció de **Holm-Bonferroni** (més potent que la correcció de Bonferroni clàssica) sobre els 6 p -valors bruts de cada mètrica.

La correcció de Holm funciona ordenant els p -valors bruts $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$ i comparant cada un amb el llindar $\alpha/(m - i + 1)$, on $m = 6$ i $\alpha = 0.05$.

5.2 Normalitat (Shapiro-Wilk)

Taula 2: p -valors del test de Shapiro-Wilk per a cada model i mètrica.

Mètrica	NB_Full	ANB_Full	NB_MB	ANB_MB
Accuracy	0.3840	0.2225	0.8962	0.8315
AUC	0.8463	0.0519	0.1343	0.3915
Brier	0.5099	0.1052	0.3702	0.4083

Tots els p -valors superen el llindar 0.05: s'accepta normalitat per a tots els models i mètriques, de manera que s'aplica el *Paired t-test* unilateral en totes les comparacions per parells.

5.3 Tests per Parells — Accuracy

Taula 3: Comparació per parells — Accuracy (Paired t-test unilateral + Holm).

Model 1	Model 2	Mitja 1	Mitja 2	p brut	p Holm	Sig.
NB_Full	ANB_Full	0.7238	0.7028	3.23×10^{-6}	1.94×10^{-5}	***
NB_Full	NB_MB	0.7238	0.7199	2.96×10^{-2}	8.75×10^{-2}	ns
NB_Full	ANB_MB	0.7238	0.7175	2.92×10^{-2}	8.75×10^{-2}	ns
NB_MB	ANB_Full	0.7199	0.7028	4.17×10^{-5}	1.75×10^{-4}	***
ANB_MB	ANB_Full	0.7175	0.7028	3.50×10^{-5}	1.75×10^{-4}	***
NB_MB	ANB_MB	0.7199	0.7175	1.69×10^{-1}	1.69×10^{-1}	ns

5.4 Tests per Parells — AUC

Taula 4: Comparació per parells — AUC (Paired t-test unilateral + Holm).

Model 1	Model 2	Mitja 1	Mitja 2	p brut	p Holm	Sig.
NB_Full	ANB_Full	0.7993	0.7824	3.30×10^{-5}	1.98×10^{-4}	***
NB_Full	NB_MB	0.7993	0.7961	1.62×10^{-2}	3.23×10^{-2}	*
NB_Full	ANB_MB	0.7993	0.7937	9.21×10^{-4}	2.76×10^{-3}	**
NB_MB	ANB_Full	0.7961	0.7824	6.31×10^{-5}	3.15×10^{-4}	***
ANB_MB	ANB_Full	0.7937	0.7824	3.69×10^{-4}	1.48×10^{-3}	**
NB_MB	ANB_MB	0.7961	0.7937	3.42×10^{-2}	3.42×10^{-2}	*

5.5 Tests per Parells — Brier Score (Mètrica Decisiva)

Taula 5: Comparació per parells — Brier Score (Paired t-test unilateral + Holm).

Model millor	vs. Model	Mitja millor	Mitja altre	p brut	p Holm	Sig.
ANB_Full	NB_Full	0.1985	0.2251	1.31×10^{-7}	3.94×10^{-7}	***
NB_MB	NB_Full	0.2028	0.2251	4.82×10^{-8}	2.41×10^{-7}	***
ANB_MB	NB_Full	0.1886	0.2251	7.78×10^{-9}	4.67×10^{-8}	***
ANB_Full	NB_MB	0.1985	0.2028	6.80×10^{-3}	6.80×10^{-3}	**
ANB_MB	ANB_Full	0.1886	0.1985	1.42×10^{-5}	2.84×10^{-5}	***
ANB_MB	NB_MB	0.1886	0.2028	6.65×10^{-8}	2.66×10^{-7}	***

*ns: $p \geq 0.05$; *: $p < 0.05$; **: $p < 0.01$; ***: $p < 0.001$. Tots els p -valors mostrats ja han estat corregits amb Holm.*

5.6 Interpretació dels Tests

L'**ANB_MB** és l'únic model amb el Brier Score significativament inferior a tots els altres ($p < 0.001$ després de la correcció Holm). Per contra, les diferències en Accuracy i AUC entre **ANB_MB** i **NB_Full**/**NB_MB** no assoleixen significació estadística un cop aplicada la correcció. Això confirma que la superioritat del model escollit es basa en la **cal·libració probabilística**, no en l'exactitud bruta.

6 Model Final i Casos Representatius

Un cop validats i comparats tots els models, s'ha seleccionat l'**ANB_MB** com a model final per les raons detallades a la secció 7. El model s'ha reeditat sobre la totalitat del *dataset* ($N = 9.131$) i la inferència es realitza via Junction Tree (gRain).

6.1 Cas 1: Equip Blau Dominant (Snowball)

Escenari: L'equip blau té or molt alt (n_6), experiència alta (n_5), morts molt baixes (n_1), ha capturat el Drac i el vermell ha perdut una torre. L'equip vermell parteix d'experiència baixa (n_2).

- **Probabilitat estimada de victòria: 77,66 %**
- **Interpretació:** El model reflecteix la dinàmica de *snowball*: l'avantatge econòmic combinat amb objectius neutrals es tradueix en una probabilitat de victòria molt elevada al minut 10.

6.2 Cas 2: Bon Farm sense Objectius

Escenari: L'equip blau té un or per sobre de la mitjana (n_4) però no ha capturat cap objectiu neutral ni destruït torres. El vermell tampoc.

- **Probabilitat estimada de victòria:** 54,74 %
- **Interpretació:** Un bon *farming* sense pressió d'objectius no garanteix victòria. El model valora que l'avantatge econòmic és moderat i que l'absència d'objectius fa la partida incerta.

6.3 Cas 3: Equip Blau en Desavantatge

Escenari: L'equip blau té or i experiència baixos (n_2), moltes morts (n_6); el vermell controla Drac, Herald i ha destruït una torre.

- **Probabilitat estimada de victòria:** 7,08 %
- **Interpretació:** El model captura fidelment el pes acumulat dels objectius; tres avantatges combinats al vermell deixen el blau gairebé sense opcions al minut 10.

6.4 Cas 4: Avantatge Parcial (Drac, Or Igualat)

Escenari: Or, experiència i morts similars entre equips (n_4/n_3), però el blau ha capturat el Drac.

- **Probabilitat estimada de victòria:** 64,96 %
- **Interpretació:** El Drac proporciona un avantatge moderat però no definitiu quan l'economia és igualada, consistent amb la teoria del joc.

Taula 6: Resum de l'estudi de casos — Model ANB_MB.

#	Situació	Descripció breu	$P(\text{victòria})$
1	Dominant	Or alt, exp alta, drac, torre, roig debilitat	77,66 %
2	Farm passiu	Bon CS però sense objectius ni kills rellevants	54,74 %
3	Desavantatge	Roig amb drac, herald i torre; blau escàs d'or	7,08 %
4	Avantatge parcial	Drac blau, or similar entre equips	64,96 %

7 Conclusions

7.1 Selecció del Model Final: ANB_MB

L'ANB_MB s'ha seleccionat per tres raons fonamentals:

1. **Principi de parsimònia:** Amb 10 variables i 18 arcs, el model redueix les 23+ variables del *dataset* original sense pèrdua significativa de capacitat predictiva (les diferències en Accuracy i AUC respecte a NB_Full **no** són estadísticament significatives després de la correcció Holm).
2. **Cal·libració probabilística (Brier Score = 0,1886):** L'ANB_MB és significativament millor que tots els altres models ($p < 0.001$ amb correcció Holm), cosa que indica que les probabilitats del model són més fiables i menys “confiades en excés”. Això és especialment rellevant per a l'aplicació pràctica: un model ben cal·librat proporciona probabilitats útils per a la presa de decisions (p. ex. saber que una situació “sembla fàcil” però el model li dona un 70 % implica que hi ha incertesa real).
3. **BIC:** $-122,425.3$, el millor entre els models reduïts, penalitzant adequadament la complexitat dels 18 arcs.

7.2 Predictors Clau

L'anàlisi de la Informació Mútua dels arcs confirma que **l'Or total** (`blueTotalGold_disc`) i **l'Experiència** (`blueTotalExperience_disc`) de l'equip blau són els predictors amb major pes a la xarxa. Segueixen de prop `blueDeaths_disc` i `redTotalExperience_disc`, que capten el diferencial d'estat entre equips. Les variables de visió (*wards*) i de jungla (`blueTotalJungleMinionsKill`) aporten informació complementària però de menor magnitud.

7.3 Limitacions del Model

1. **Horitzó temporal:** El minut 10 és un instant primerenc. Factors com la composició d'equips (*team composition*), l'habilitat individual i les decisions estratègiques de la fase mitja i tardana de la partida no estan captures al *dataset*.
2. **Efecte de la discretització:** La conversió de variables contínues a categories implica una pèrdua d'informació inherent. Mètodes com les xarxes bayesianes amb distribucions gaussianes (*Gaussian BN*) podrien evitar aquest trade-off.
3. **Independències imposades:** Tot i ser un ANB, el model assumeix certes independències que poden no ser vàlides, especialment entre variables del mateix equip.

7.4 Propostes de Millora

1. **Noves variables derivades:** Incloure variables com la diferència d'or entre equips ($\Delta\text{Gold} = \text{blueTotalGold} - \text{redTotalGold}$), que captura directament l'avantatge relatiu. Un model preliminar va suggerir que aquesta variable pot tenir un poder predictiu igual o superior a l'or absolut.

2. **Dades a minuts múltiples:** Si es disposés de dades als minuts 5, 10 i 15 per a cada partida, es podria construir una xarxa bayesiana dinàmica (*Dynamic BN*) que modelés l'evolució temporal de l'estat de la partida.
3. **Aprenentatge d'estructura alternatiu:** Algoritmes com MMHC (*Max-Min Hill-Climbing*) o PC combinen restriccions de CI-tests amb cerca *score-based* i podrien obtenir millors estructures amb menys arcs espuris.
4. **Variables no incloses:** Dades com el rang específic del jugador (*LP* dins de Diamant/Màster), la composició de campions o l'ordre de les accions (*event log*) podrien millorar substancialment la capacitat predictiva del model.
5. **Models híbrids:** L'ús de xarxes bayesianes com a capa de probabilitat posterior sobre un classificador de gradient boosting (p. ex. XGBoost) podria combinar la interpretabilitat de les primeres amb la capacitat predictiva dels darrers.

7.5 Reflexió sobre l'ús de la Intel·ligència Artificial

Considerem que l'us de la intel·ligència artificial pot influir negativament en l'aprenentatge de l'estudiant si no se'n fa un bon us i nosaltres en som conscient. De manera que per aquest treball hem utilitzat la IA sense que interfereixi en el nostre procés de aprenentatge. L'us d'aquesta eina es limita a: Ajuda amb el codi Latex per la compilació del informe, correcció de faltes ortogràfiques, identificació d'errors en el codi i ajuda amb la cerca bibliogràfica.