



UNIVERSITAT AUTÒNOMA DE BARCELONA

GRAU EN ESTADÍSTICA APLICADA

Models Lineals II

Anàlisi del Dataset Pixel

Autor/a: Carlos Torras, Pau Verdejo, Paulina Toro, Pol Ortiz

Data: 6 d'octubre de 2026

Índex

1	Presentació tipus d'estudi i context	3
1.1	Introducció al context clínic i tecnològic	3
1.2	Descripció del problema i procediment experimental	3
1.3	Objectius de la investigació	4
1.4	Disseny estadístic i justificació del marc analític	4
2	Presentació i anàlisi descriptiva de les dades	5
2.1	Estructura del dataset i resum estadístic	5
2.2	Anàlisi univariant: Distribució de la intensitat	5
2.3	Evolució temporal i efecte del subjecte	6
2.4	Anàlisi de la simetria lateral (Efecte Side)	7
2.5	Tendència mitjana i proposta de modelatge	9
3	Metodologia i Fonamentació Matemàtica	10
3.1	Tractament de variables i transformacions	10
3.2	Especificació del Model Lineal Mixt (LMM)	10
3.3	Estimació per Màxima Versemblança Restringida (REML)	10
3.4	Criteri d'Informació d'Akaike (AIC)	10
3.5	Test de Raó de Versemblances (LRT)	11
4	Ajust del model i diagnosi de validesa	12
4.1	Anàlisi de Linealitat i Homocedasticitat	12
4.2	Normalitat dels residus: Anàlisi gràfica i analítica	12
4.3	Independència i Multicol·linealitat	13
4.4	Detecció de Punts Influent: Distància de Cook	14
4.5	Anàlisi de l'estructura de correlació temporal (AR1)	14
4.6	Conclusió de la Diagnosi	15
5	Resultats i Discussió	16
5.1	Comparació de models i tria del definitiu	16
5.1.1	Criteris d'avaluació i bondat d'ajust	16
5.1.2	Tria del model final	16
5.2	Interpretació del model	16
5.2.1	Interpretació dels Coeficients de Regressió	17
5.2.2	Anàlisi de la trajectòria temporal	17
5.2.3	Variabilitat Aleatòria (Component de Gos)	17
6	Conclusions	18
6.1	Limitacions i futures línies d'investigació	19
A	Anexos: Implementació tècnica en R	20
A.1	Preparació del entorn i carrega de dades	20
A.2	Exploració estadística inicial	20
A.3	Anàlisi descriptiu i visualització	20
A.4	Propostes de models i comparació	21

A.5	Verificació de hipòtesis y diagnòstic	21
A.6	Análisis de influencia	23

1 Presentació tipus d'estudi i context

1.1 Introducció al context clínic i tecnològic

L'estudi de la densitat òssia i el comportament dels teixits mitjançant tècniques de diagnòstic per la imatge ha esdevingut un pilar fonamental en la medicina veterinària contemporània. Fent ús de tecnologies com ara els processos de computació tomogràfica o ressonàncies magnètiques, es fa possible per als experts obtenir representacions detallades de l'anatomia interna a través de la mesura de l'atenuació dels raigs X. Aquesta atenuació es tradueix digitalment en una matriu de píxels, on cada valor d'intensitat reflecteix la densitat del teixit explorat.




Figura 1: Ressonància Magnètica (RM) lateral de la columna d'un gos.

En aquesta mena de procediments, típicament es fa ús de medis de contrastos al aportar claredat a les imatges d'algunes estructures internes. Aquests contrastos estan normalment constituïts per yode o gadolini, ja que al ser elements paramagnètics, al efectuar la tomografia o la ressonància la substància es distribueix uniformement pel còs de l'animal generant un contrast entre els diferents teixits.

L'estudi de la densitat òssia i el comportament dels teixits mitjançant tècniques de diagnòstic per la imatge ha esdevingut un pilar fonamental en la medicina veterinària contemporània. Fent ús de tecnologies com ara els processos de computació tomogràfica o ressonàncies magnètiques, es fa possible per als experts obtenir representacions detallades de l'anatomia interna a través de la mesura de l'atenuació dels raigs X. Aquesta atenuació es tradueix digitalment en una matriu de píxels, on cada valor d'intensitat reflecteix la densitat del teixit explorat.

En el context d'aquest treball, s'analitza l'ús d'agents de contrast injectables, els quals són essencials per millorar la visibilitat d'estructures amb baixa diferenciació natural. L'estudi del conjunt de dades *Pixel* se centra precisament en l'evolució temporal d'aquesta intensitat radiològica després de l'administració del contrast.

1.2 Descripció del problema i procediment experimental

L'experiment recollit en la base de dades es va dur a terme sobre una mostra de deu gossos, identificats mitjançant la variable *Dog* amb nivells de l'1 al 10. Pensem que és convenient que s'estudi l'evolució de l'efecte dels contrastos en un grup de gossos diferents ja que aquest efecte dins de cada animal pot variar depenent de la seva constitució, raça o condicions físiques.

El disseny de l'estudi es basa en la captura seqüencial d'imatges en diferents punts temporals després de la injecció del medi de contrast per observar-ne la degradació o persistència.

Les observacions es van realitzar en diversos dies post-injecció. Per cada escaneig realitzat periòdicament s'en va registrar el dia el qual es va dur a terme a partir de l'aplicació del contrast a la variable `day`. Hi ha observacions es prenen des de el mateix dia de l'injecció del contrast i en alguns casos s'arriben a registrar mesures de fins a dues setmanes deprés. Una característica essencial del disseny és la duplicitat de mesures segons el costat escanejat de l'animal (`Side`), diferenciant entre el costat esquerre (L) i el dret (R) per poder garantir que es realitza un anàlisi prou robust. En total, es disposa de 102 registres que recullen la intensitat del píxel (`pixel`).

1.3 Objectius de la investigació

Establim com a objectiu principal en aquest informe el determinar un model estadístic que sigui capaç de descriure amb precisió l'evolució de la intensitat del píxel en funció del temps. D'aquesta forma es pot obtenir un major coneixement de l'efecte dels medis de contrast i possiblement fer-ne un ús més efectiu. Concretament, es pretén:

- **Modelitzar l'evolució del contrast a través del temps:** Identificar la tendència que segueix la variable `pixel` al llarg del període de seguiment posterior a l'injecció i definir un model que s'ajusti bé a les dades recopilades.
- **Avaluar la simetria lateral:** Avaluar de forma estadística si el factor `Side` té un efecte significatiu sobre la intensitat de píxel mesurat i si per tant l'efecte del contrast es distribueix uniformement pel cos del animal estudiat.
- **Controlar la variabilitat associada als diferents subjectes individuals:** Quantificar la influència de cada gos (`Dog`) en la variabilitat total de les dades.

1.4 Disseny estadístic i justificació del marc analític

Des del punt de vista de l'anàlisi estadística, aquest estudi s'emmarca dins dels models de mesures repetides o dades longitudinals. Atès que les mesures s'han realitzat sobre els mateixos individus en diferents moments, no podem assumir la independència de les observacions.

Aquestes dades analitzades estadísticament constitueixen un estudi de dades longitudinals amb mesures repetides. S'ha de tenir en compte aquesta estructura ja que no fer-ho pot donar peu a obtenir conclusions errònies sobre la significació dels predictors. Seguint això, desenvoluparem el treball utilitzant **Models Lineals Mixtes (LMM)**, els quals són ideals per captar en el model els efectes fixes com ara el temps, i a l'hora la variabilitat aleatòria que apareix al afegir diferents subjectes amb les seves diferents observacions individuals.

2 Presentació i anàlisi descriptiva de les dades

Abans de iniciar el procés de modelització formal realitzarem una exploració exhaustiva del conjunt de dades *Pixel* per poder tenir un coneixement més profund de la seva estructura i naturalesa. És fonamental dur a terme aquesta fase per poder-nos fer una bona idea de la definició real de les variables estudiades, així com per orientar les decisions metodològiques posteriors.

Tenim l'intenció de presentar de forma resumida les característiques més essencials de les variables del conjunt, i analitzar si aparèixen possibles patrons rellevants o relacions que no apreciem a simple vista. També tractarem d'identificar si existeixen valors extrems o atípics (outliers) que poguessin estar influïnt significativament en els resultats.

2.1 Estructura del dataset i resum estadístic

102 observacions formen el total del conjunt de dades recollides sobre 10 subjectes (gossos) diferents. Per a cada observació es pren la mesura de 3 variables diferents, excloent `gos`; que indica el subjecte. `day` conté informació del moment en el temps en el que s'ha mesurat, és a dir, la quantitat de dies des de la suministració del contrast, `Side` reflexa quin costat del gos ha estat escanejat i `pixel` mostra l'intensitat de píxel mesurada.

A continuació, es presenta un resum numèric de la variable resposta (`pixel`), la qual es l'epicentre d'aquest estudi estadístic:

Variable	Mínim	1r Quartil	Mediana	Mitjana	3r Quartil	Màxim
Intensitat (<code>pixel</code>)	1034,1	1053,9	1087,7	1086,9	1109,6	1161,1

Taula 1: Resum estadístic descriptiu de la intensitat dels píxels en el dataset *Pixel*.

A partir d'aquesta taula resum, observem que la mediana i la mitjana presenten valors quasi idèntics (1086,9 vs 1087,7). Això suggereix que la distribució de les dades es força simètrica, sense existir biaixos extrems.

2.2 Anàlisi univariant: Distribució de la intensitat

Per tal de visualitzar millor la forma de la distribució, grafiquem i analitzem l'histograma de la variable `pixel`. Aquest gràfic és vital per a l'informe ja que per a validar els contrastos d'hipotesis s'ha de complir l'assumpció de normalitat dels residus, la qual sol estar lligada a la distribució de la variable resposta en estudis d'aquest tipus.




Figura 2: Histograma i corba de densitat de la intensitat de píxels. S'observa una distribució unimodal que s'aproxima a la campana de Gauss.

L'histograma confirma que no hi ha presència a priori de *outliers* severos que puguin distorsionar les estimacions per mínims quadrats. La forma unimodal ens dona confiança per procedir amb el modelatge lineal.

2.3 Evolució temporal i efecte del subjecte

Com que estem davant d'un estudi longitudinal, la relació més important és la de la intensitat del contrast amb el temps (*day*). No obstant això, aquesta relació no es pot analitzar de forma agregada sense tenir en compte que cada gos té les seves pròpies característiques.

El gràfic d'espaguetti següent permet visualitzar la trajectòria de cadascun dels 10 gossos al llarg dels 21 dies del seguiment, per així fer-nos una idea de el comportament tant individual com col·lectiu dels gossos amb diferents trets. Es mostren les trajectòries de l'intensitat tant per els escanetjos del costat dret com l'esquerra.




Figura 3: Gràfic d'espagueti: Evolució de la intensitat del píxel per a cada gos segons el costat. Cada línia representa un individu.

Aquesta visualització ens permet extreure informació sobre les dades rellevant per la construcció del model posteriorment:

1. **Heterogeneïtat de base:** Els gossos no comencen en el mateix valor d'intensitat al dia 0. Això justifica la inclusió de l'**intercepte aleatori** per gos.
2. **Tendència temporal:** S'observa un increment general de la intensitat durant els primers 10 dies, seguit d'una certa estabilització. Aquesta curvatura ens indica que un model lineal simple podria ser insuficient i que caldria explorar un **model quadràtic**.
3. **Variabilitat en el creixement:** Les pendents de les línies no són exactament paral·leles, el que suggereix que l'efecte del temps podria variar segons el gos (pendent aleatòria).

2.4 Anàlisi de la simetria lateral (Efecte Side)

Un altre objectiu de l'estudi és determinar si el costat del cos on es realitza la ressonància influeix en la mesura. Atès que cada gos té mesures en ambdós costats, comparem les distribucions mitjançant un diagrama de caixa (*boxplot*).




Figura 4: Comparació de la intensitat de píxels entre el costat esquerre (L) i el dret (R).

Les mitjanes i les mitjanes interquartíliques són pràcticament idèntiques per a ambdós costats. Visualment, no hi ha indicis que el costat (**Side**) sigui un predictor rellevant de la intensitat, tot i que s'observa que el costat dret presenta una mitjana lleugerament inferior. Aquesta hipòtesi es contrastarà formalment mitjançant el modelatge i el càlcul dels p-valors en seccions posteriors, on el que s'espera és que el coeficient que capti l'informació de (**Side**) no sigui significatiu.

2.5 Tendència mitjana i proposta de modelatge

Finalment, observem la línia de tendència mitjana ajustada per mètodes no paramètrics (*LOESS*).




Figura 5: Tendència mitjana de l'estudi. La curvatura observada motiva la inclusió d'un terme quadràtic per al temps.

En conjunt, l'anàlisi descriptiva del conjunt de dades *Pixel* ha permès obtenir una visió clara i força completa del comportament de les observacions abans d'entrar en la fase de modelatge formal. L'estudi de la distribució de la variable resposta indica que la intensitat del píxel presenta una estructura raonablement simètrica, sense la presència de valors extrems greus que puguin comprometre l'estabilitat de les estimacions, fet que dona confiança per treballar dins del marc dels models lineals.

L'exploració gràfica de l'evolució temporal posa de manifest que la relació entre la intensitat i el temps no és estrictament lineal. Tant els gràfics d'espagueti com la tendència mitjana ajustada mitjançant LOESS suggereixen un increment inicial de la intensitat durant els primers dies, seguit d'una fase de saturació o estabilització. Aquest comportament justifica clarament la necessitat d'incorporar el temps de manera no lineal, mitjançant un terme quadràtic, per tal de capturar adequadament la dinàmica del procés observat.

A més, les diferències evidents en els valors inicials d'intensitat entre els gossos indiquen l'existència d'una marcada heterogeneïtat individual. Aquesta variabilitat entre subjectes fa inapropiat tractar les observacions com a independents i reforça la conveniència de considerar una estructura jeràrquica en el model, mitjançant la inclusió d'efectes aleatoris per gos. Pel que fa a l'efecte del costat escanejat, l'anàlisi descriptiva no aporta evidències clares d'una diferència rellevant, tot i que aquest aspecte haurà de ser contrastat formalment en fases posteriors.

En definitiva, aquesta descripció exhaustiva de les dades permet concloure que el model definitiu haurà d'integrar el temps de forma no lineal i gestionar l'estructura jeràrquica dels subjectes mitjançant efectes aleatoris per gos, establint així una base sòlida i coherent per al modelatge estadístic posterior.

3 Metodologia i Fonamentació Matemàtica

En aquesta secció es descriu l'enfocament estadístic utilitzat per modelitzar la intensitat dels píxels. Donada la naturalesa longitudinal del dataset *Pixel*, la metodologia se centra en la transició des dels models de regressió clàssics cap als models lineals d'efectes mixtes (LMM).

3.1 Tractament de variables i transformacions

A partir de l'anàlisi exploratòria realitzada a la Secció 2, s'han pres les següents decisions metodològiques:

- **Variable Temporal (day):** S'introdueix un terme lineal i un terme quadràtic (day^2). Això permet capturar la desacceleració en l'atenuació del contrast observada als gràfics LOESS.
- **Factors:** *Side* s'analitza com a efecte fix i *Dog* com a factor d'agrupament per als efectes aleatoris.

3.2 Especificació del Model Lineal Mixt (LMM)

El model es defineix seguint la notació de Laird i Ware (1982):

$$y_i = X_i\beta + Z_i b_i + \varepsilon_i \quad (1)$$

On y_i és el vector de respostes per al gos i , $X_i\beta$ són els efectes fixos i $Z_i b_i$ els efectes aleatoris, amb $b_i \sim N(0, D)$ i $\varepsilon_i \sim N(0, \sigma^2 I)$.

3.3 Estimació per Màxima Versemblança Restringida (REML)

L'estimació per Màxima Versemblança (ML) convencional tendeix a infraestimar les components de variància (σ^2 i D) perquè no té en compte els graus de llibertat perduts en estimar els efectes fixos β .

Per solucionar-ho, utilitzem el mètode ****REML****. Matemàticament, REML maximitza la versemblança d'un conjunt de combinacions lineals de les dades (Ky) tals que $E[Ky] = 0$. Si definim $P = V^{-1} - V^{-1}X(X'V^{-1}X)^{-1}X'V^{-1}$, la funció de log-versemblança restringida és:

$$L_{REML} = -\frac{1}{2} [\log |V| + \log |X'V^{-1}X| + y'Py] \quad (2)$$

Aquesta correcció és vital en el dataset *Pixel* atès el nombre limitat de subjectes ($n = 10$), assegurant estimacions de variància més robustes.

3.4 Criteri d'Informació d'Akaike (AIC)

Per a la comparació de models no niats o amb diferents estructures de variància, utilitzem l'****AIC****. Aquest criteri penalitza la complexitat del model per evitar el sobreajust (*overfitting*):

$$AIC = -2 \log(L) + 2k \quad (3)$$

On L és la versemblança maximitzada i k és el nombre total de paràmetres estimats (efectes fixos més components de variància i covariància). En el nostre estudi, triarem el model amb l'AIC més baix, ja que representa el millor equilibri entre parsimònia i qualitat de l'ajust.

3.5 Test de Raó de Versemblances (LRT)

Per comparar models niats (per exemple, per decidir si incloure una pendent aleatòria), utilitzem el **LRT**. L'estadístic de contrast es defineix com:

$$\lambda_{LR} = -2 \ln \left(\frac{L_{null}}{L_{alt}} \right) = 2(l_{alt} - l_{null}) \quad (4)$$

Sota la hipòtesi nul·la, λ_{LR} segueix una distribució χ^2 amb graus de llibertat iguals a la diferència de paràmetres entre els models.

Nota metodològica: Quan comparem models amb diferents efectes fixos mitjançant LRT, és obligatori utilitzar l'estimació ML en lloc de REML, ja que les versemblances restringides no són comparables si les matrius de disseny X varien. Tanmateix, per comparar estructures aleatòries (mateixos efectes fixos), el REML és el mètode correcte.

4 Ajust del model i diagnosi de validesa

Un cop seleccionat el model lineal mixt amb intercepte i pendent aleatòria per al temps, procedim a realitzar una diagnosi exhaustiva dels residus. Aquest pas és crític per garantir que les conclusions del treball siguin fiables i que el model s'ajusta correctament a la realitat física del dataset *Pixel*.

4.1 Anàlisi de Linealitat i Homocedasticitat

La linealitat s'ha verificat mitjançant el gràfic de residus enfront de valors ajustats. Atès que hem inclòs un component quadràtic per al temps, s'espera que no quedi cap patró corbat residual.




Figura 6: Gràfic de residus vs. valors ajustats. La dispersió aleatòria i l'absència de tendències sistemàtiques confirmen que la forma funcional (lineal-quadràtica) és adequada.

A la Figura 6, observem que els residus es distribueixen de manera homogènia al voltant de l'eix horitzontal. Per confirmar l'homocedasticitat (variància constant), hem aplicat el **Test de Breusch-Pagan**, obtenint un p-valor de **0,6251**. Com que aquest valor és superior a 0,05, no podem rebutjar la hipòtesi d'homocedasticitat, validant així l'ús del mètode REML per a les estimacions.

4.2 Normalitat dels residus: Anàlisi gràfica i analítica

L'assumpció de normalitat s'ha contrastat mitjançant el gràfic de probabilitat normal (QQ-plot) i el test de Shapiro-Wilk.




Figura 7: Gràfic QQ-plot dels residus. El seguiment dels punts sobre la línia de referència indica que l'assumpció de normalitat és plenament satisfeta.

El **Test de Shapiro-Wilk** ha proporcionat un p-valor de **0,6162**. Aquest resultat ens permet mantenir la hipòtesi nul·la de normalitat, assegurant que les proves z i els intervals de confiança per als coeficients que calcularem a la Secció 5 siguin correctes.

4.3 Independència i Multicol·linealitat

En dades longitudinals, la independència és sovint l'assumpció més difícil de complir. El test de **Durbin-Watson** presenta un valor de **1,1222**. Un valor d'1,12 indica una lleugera autocorrelació positiva entre les mesures temporals del mateix gos, un fet esperable en aquest tipus d'estudis. No obstant això, l'especificació d'un model mixt precisament mitiga aquest problema en modelitzar la correlació intra-subjecte a través dels efectes aleatoris.

Pel que fa a la multicol·linealitat, els valors del **Factor d'Inflació de la Variància (VIF)** obtinguts són els següents:

- day: 8,74
- day²: 8,74
- Side: 1,00

Malgrat que els valors per al temps i el seu quadrat s'apropen al llindar de 10, aquesta multicol·linealitat és de naturalesa estructural (relació entre una variable i la seva potència) i no invalida la capacitat predictiva del model ni l'estabilitat dels coeficients en aquest context.

4.4 Detecció de Punts Influent: Distància de Cook

Per avaluar si algun subjecte (gos) està exercint una influència desproporcionada en l'estimació dels paràmetres del model mixt, hem calculat la **Distància de Cook** a nivell de grup (*subject-level influence*). En models longitudinals, és més rellevant identificar subjectes atípics que observacions individuals, ja que la unitat experimental és el gos.




Figura 8: Distància de Cook per subjecte. S'utilitza el llindar de $4/N$ (0,4 per a 10 gossos) com a referència per identificar casos potencialment influents.

Com s'observa a la Figura 8, el **gos número 4** presenta una distància de Cook superior a 1,0, superant clarament el llindar crític de 0,4. Una revisió detallada de les seves dades indica que els seus valors de píxel segueixen una trajectòria més pronunciada que la mitjana. No obstant això, atès que no hi ha indicis que es tracti d'un error de mesura i que el model mixt està dissenyat precisament per absorbir aquesta variabilitat inter-individual mitjançant efectes aleatoris, s'ha decidit mantenir-lo en l'anàlisi per no perdre generalització en els resultats biològics.

4.5 Anàlisi de l'estructura de correlació temporal (AR1)

Atès que el test de Durbin-Watson ha suggerit la presència d'autocorrelació residual, hem explorat si un model amb una estructura de correlació autoregressiva de primer ordre (**AR1**) seria més adequat. En dades de bio-imatge preses seqüencialment, és comú que el residu al temps t estigui correlacionat amb el residu al temps $t - 1$.




Figura 9: Gràfic de dispersió dels residus en el temps t vs. temps $t - 1$. La tendència lineal positiva confirma la hipòtesi d'autocorrelació de primer ordre ($\rho \approx 0,44$).

Hem comparat el model original (independència de residus) amb un model que incorpora una matriu de correlació AR1 per a l'error intra-subjecte:

- **Model Original (Random Slopes):** AIC = 895,4
- **Model amb AR1:** AIC = 882,1

La reducció significativa de l'AIC (Criteri d'Informació d'Akaike) en més de 10 unitats indica que el model AR1 proporciona un millor ajust estadístic. Tanmateix, les estimacions dels efectes fixos (**day**, **day²** i **Side**) s'han mantingut molt estables en ambdós models, fet que demostra la robustesa del model mixt inicial. Per simplicitat interpretativa i seguint el principi de parsimònia, es manté el model de pendents aleatòries com a base, reconeixent però que la correlació temporal és un factor rellevant en la dinàmica dels píxels.

4.6 Conclusió de la Diagnosi

En resum, el model supera satisfactòriament les proves de linealitat, normalitat i homocedasticitat. Tot i la identificació d'un subjecte influent (Gos 4) i d'una estructura de correlació temporal AR1 que podria refinar l'ajust, els supòsits fonamentals es mantenen prou sòlids per procedir a la interpretació dels resultats en la següent secció.

5 Resultats i Discussió

En aquesta secció es detallen els resultats de l'ajust dels models lineals mixtes per al conjunt de dades *Pixel*. L'anàlisi es divideix en la comparació formal de les estructures candidates i la interpretació dels paràmetres del model seleccionat.

5.1 Comparació de models i tria del definitiu

La selecció del model definitiu s'ha dut a terme mitjançant un procediment de construcció ascendent (*forward stepwise*), on hem avaluat l'impacte d'afegir components aleatoris i termes no lineals a la variable temporal.

5.1.1 Criteris d'avaluació i bondat d'ajust

Per a la comparació entre els models hem utilitzat un ventall de mètriques que permeten equilibrar la capacitat explicativa amb la parsimònia del model:

- **Criteris d'Informació (AIC i BIC):** S'ha buscat la minimització d'aquests valors. L'AIC del model de regressió simple inicial (OLS) era de 977,67, mentre que en introduir l'efecte aleatori per gos ha davallat fins als 888,23, confirmant la necessitat de l'estructura mixta.
- **Coeficients de Determinació (R^2):**
 - El R^2 **Marginal** és de 0,0802, indicant que els efectes fixos (dia i costat) expliquen aproximadament el 8% de la variabilitat total.
 - El R^2 **Condiciona**l assoleix el 0,7337, fet que demostra que el model, incloent la variabilitat individual dels gossos, és capaç d'explicar el 73,37% de la variància de la intensitat dels píxels.
- **Test de Raó de Versemblances (LRT):** La comparació entre el model d'intercepte aleatori i el de pendent aleatòria ha resultat en un p-valor de 0,8783, el que ens porta a acceptar el model més senzill d'intercepte aleatori.

5.1.2 Tria del model final

El model final escollit inclou els efectes fixos de **day**, **day**² i **Side**, i un efecte aleatori per a cada **Dog** sobre l'intercepte. Malgrat que el factor **Side** presenta un p-valor marginal ($p = 0,090$ en l'estimació REML), s'ha decidit mantenir-lo en el model per la seva rellevància en el context de l'estudi de la simetria de regeneració post-injecció.

5.2 Interpretació del model

Un cop ajustat el model mitjançant el mètode de Màxima Versemblança Restringida (REML), procedim a la interpretació dels coeficients estimats β_i .

Predictor	Coefficient (β)	Error Estàndard	Valor z	p -valor
(Intercepte)	1076,88	9,255	116,36	$< 0,001$
Side[T.R]	-5,40	3,184	-1,70	0,090
day	4,94	1,030	4,79	$< 0,001$
day ²	-0,25	0,053	-4,75	$< 0,001$

Taula 2: Estimacions dels efectes fixos del model final.

5.2.1 Interpretació dels Coeficients de Regressió

1. **Intercepte** ($\beta_0 = 1076,88$): Representa la intensitat mitjana esperada del píxel en el dia 0 (moment de la injecció) per al costat esquerre (referència). És el punt de partida basal de la densitat radiològica en el conjunt de la mostra.
2. **Efecte del Costat** ($\beta_{Side} = -5,40$): Per a un mateix gos i en un mateix dia, s'estima que el costat dret (R) té una intensitat 5,40 unitats inferior a la del costat esquerre. El p -valor no és molt significatiu (0,090), però no és totalment negligible, així que podem pensar que el costat té un efecte sobre la intensitat mitjana del píxel que no hauriem d'ignorar.
3. **Efecte del Temps (Terme Lineal, $\beta_{day} = 4,94$)**: En les primeres etapes del procés, per cada dia que augmenta el temps des de la injecció, la intensitat del píxel tendeix a augmentar en 4,94 unitats, mantenint la resta de variables constants. Aquest valor reflecteix el ritme de regeneració o acumulació inicial del contrast.
4. **Efecte del Temps (Terme Quadràtic, $\beta_{day^2} = -0,25$)**: El signe negatiu del coeficient quadràtic indica que la relació entre la intensitat i el temps és parabòlica i convexa (*concave down*). Això significa que l'increment de la intensitat no és indefinit; el ritme de creixement disminueix fins a assolir un màxim, a partir del qual la intensitat comença a decréixer.

5.2.2 Anàlisi de la trajectòria temporal

A partir dels coeficients lineals i quadràtics, podem calcular el moment en què la intensitat del píxel assoleix el seu valor màxim mitjançant la derivada del model respecte al temps:

$$\frac{\partial(\text{pixel})}{\partial(\text{day})} = 4,94 + 2 \cdot (-0,25) \cdot \text{day} = 0 \implies \text{day}_{max} \approx 9,88 \text{ dies} \quad (5)$$

Això indica que l'agent de contrast assoleix la seva màxima acumulació o efecte radiològic aproximadament al **desè dia** post-injecció. Aquesta troballa és crucial per als protocols de seguiment clínic, ja que defineix la finestra temporal de màxima resolució diagnòstica.

5.2.3 Variabilitat Aleatòria (Component de Gos)

La variància associada a l'efecte aleatori del gos (**Group Var**) és de 634,54, mentre que la variància residual és de 258,56. Això implica que la variabilitat entre els diferents gossos

és molt superior a la variabilitat residual o error de mesura. El càlcul de la **Correlació Intra-classe (ICC)** ho confirma:

$$ICC = \frac{\sigma_{Dog}^2}{\sigma_{Dog}^2 + \sigma_{\varepsilon}^2} = \frac{634,54}{634,54 + 258,56} \approx 0,71 \quad (6)$$

Un ICC de 0,71 indica que el 71% de la variància no explicada pels efectes fixos és deguda a diferències intrínseques entre els gossos. Aquesta dada justifica plenament la metodologia de models mixtes escollida.

6 Conclusions

L'anàlisi aplicada al conjunt de dades *Pixel* ha permès descriure i modelitzar de manera satisfactòria el comportament temporal de la intensitat radiològica després de la injecció en subjectes canins. A partir de l'estudi realitzat, s'ha pogut captar l'evolució del senyal al llarg del temps i entendre millor els factors que intervenen en aquest procés. Tot seguit, es presenten les conclusions principals que es desprenen del modelatge estadístic desenvolupat en aquest informe, les quals sintetitzen els resultats més rellevants obtinguts i el seu interès tant des d'un punt de vista metodològic com aplicat.

Els resultats obtinguts confirmen que l'evolució de la intensitat del píxel al llarg del temps no pot descriure's adequadament mitjançant una tendència lineal constant. En aquest sentit, la incorporació d'un terme quadràtic estadísticament significatiu ($p < 0,001$) ha permès captar de manera més fidel la dinàmica del procés, posant de manifest que l'acumulació del medi de contrast segueix un patró caracteritzat per un creixement inicial marcat que, amb el pas dels dies, es va alentint de manera progressiva.

Segons el model final estimat, la intensitat radiològica assoleix el seu valor màxim aproximadament als **9,88 dies** després de la injecció. Aquesta estimació és especialment rellevant des del punt de vista clínic, ja que aporta una referència temporal clara per a la planificació dels estudis de seguiment per imatge. En concret, els resultats suggereixen que programar les exploracions al voltant del desè dia post-injecció podria permetre maximitzar la visualització i la resolució del contrast en els teixits analitzats, optimitzant així la qualitat diagnòstica de les imatges obtingudes.

L'anàlisi de la variable **Side** ha posat de manifest que, tot i no assolir un nivell de significació estadística clar i presentar un p-valor ($p = 0,090$), es detecta una diferència sistemàtica apreciable entre el costat esquerre i el costat dret. Concretament, aquesta diferència és d'aproximadament 5,40 unitats d'intensitat, la qual cosa indica que el costat escanejat pot tenir un impacte no negligible en les mesures obtingudes.

Aquest resultat suggereix que, especialment en estudis on es requereix una elevada precisió, no és recomanable considerar aquest factor com a irrellevant. Mantenir la coherència en el costat escanejat al llarg del seguiment pot ajudar a reduir la variabilitat no desitjada, i, alternativament, la incorporació de la variable **Side** com a factor de correcció dins dels models analítics podria millorar l'ajust i la interpretació dels resultats. En conjunt, tot i la seva significació limitada, l'efecte observat apunta a la conveniència de tenir en compte aquest factor en futurs estudis similars.

Un dels resultats més destacables d'aquest estudi, des d'un punt de vista metodològic, ha estat la constatació d'una elevada variabilitat inter-individual entre els gossos

analitzats. Aquesta diferència entre individus no és menor i es reflecteix clarament en un **Coefficient de Correlació Intra-classe (ICC) del 71%**, fet que indica que una part molt important de la variabilitat observada en les dades es deu a les diferències pròpies de cada animal. En aquest sentit, les característiques individuals de cada gos es confirmen com el factor amb més pes en la mesura final, situant-se clarament per sobre de l'efecte associat al pas del temps o al costat analitzat.

Davant d'aquest escenari, l'aplicació d'un **Model Lineal Mixt (LMM)** amb intercepte aleatori ha estat clau per poder capturar adequadament aquesta estructura de dependència entre observacions repetides d'un mateix individu. L'ús d'aquest enfocament ha permès millorar de manera notable la qualitat de l'ajust, incrementant el R^2 condicional fins al 73,37%, i oferint una representació més realista del comportament de les dades. Si s'hagués optat per ignorar aquesta variabilitat individual i l'estructura jeràrquica del conjunt de dades, els errors associats al model s'haurien vist infraestimats, fet que podria haver conduït a interpretacions esbiaixades i a conclusions poc fiables sobre l'efectivitat real del contrast.

6.1 Limitacions i futures línies d'investigació

Tot i que el model final mostra una bona robustesa i un ajust adequat a les dades disponibles, cal tenir en compte que aquest estudi no està exempt de limitacions, les quals convé considerar amb cautela i que obren la porta a possibles línies de recerca futures. En primer lloc, la mida de la mostra és relativament reduïda, ja que el seguiment s'ha realitzat únicament sobre 10 subjectes. Aquest fet pot condicionar la capacitat de generalitzar els resultats obtinguts a la població canina en el seu conjunt, especialment tenint en compte la variabilitat biològica existent entre individus.

D'altra banda, la finestra temporal analitzada es limita als primers 14 dies del procés, la qual cosa impedeix observar l'evolució completa de l'eliminació del contrast fins a assolir els valors basals reals. Un seguiment durant períodes més llargs podria aportar informació rellevant sobre la dinàmica a llarg termini i permetria confirmar si el comportament observat es manté estable o presenta canvis no detectats en aquest estudi.

Finalment, cal destacar que el model no incorpora certes variables potencialment rellevants, com ara l'edat, el pes o la raça dels animals. La inclusió d'aquests factors podria contribuir a explicar part del 29% de la variabilitat que actualment queda recollida com a variància residual, millorant així la capacitat explicativa del model i la seva interpretació clínica.

En conjunt, i malgrat aquestes limitacions, el model mixt quadràtic es presenta com una eina útil i funcional per a la monitorització de processos radiològics longitudinals. Els resultats obtinguts proporcionen una base raonablement sòlida per donar suport a la presa de decisions en l'àmbit del diagnòstic veterinari per imatge, tot i que futures investigacions amb mostres més àmplies i dissenys més complets podrien reforçar i ampliar les conclusions aquí presentades.

A Anexos: Implementació tècnica en R

A.1 Preparació del entorn i carrega de dades

```
1 library(lme4)
2 library(lmerTest)
3 library(MuMIn)
4 library(lmtest)
5 library(car)
6 library(influence.ME)
7 library(nlme)
8 library(ggplot2)
9 library(gridExtra)
10
11 df <- read.csv("Pixel.csv")
12 df$Dog <- as.factor(df$Dog)
```

Listing 1: Càrrega de paquets i dataset

A.2 Exploració estadística inicial

```
1 cat("Resum estadistic de la variable pixel:\n")
2 print(summary(df$pixel))
```

Listing 2: Resúm estadístico

A.3 Anàlisi descriptiu i visualització

```
1 cat("\nTaula de freqüències (Dog vs Side):\n")
2 print(table(df$Dog, df$Side))
3
4 p1 <- ggplot(df, aes(x = pixel)) +
5   geom_histogram(aes(y = ..density..), bins = 15, fill = "#69b3a2",
6     color = "white") +
7   geom_density(alpha = 0.2, fill = "#404080") +
8   labs(title = "Distribucio de la Intensitat", x = "Pixel", y = "
9     Densitat") +
10   theme_minimal()
11
12 p2 <- ggplot(df, aes(x = day, y = pixel, group = interaction(Dog,
13   Side), color = as.factor(Dog))) +
14   geom_line(alpha = 0.6) +
15   geom_point() +
16   facet_wrap(~Side) +
17   labs(title = "Evolucio temporal de la intensitat per Gos i Costat
18     ",
19     x = "Dies post-injeccio", y = "Intensitat (pixel)", color =
20     "Gos") +
```

```

16   theme_minimal()
17
18 p3 <- ggplot(df, aes(x = Side, y = pixel, fill = Side)) +
19   geom_boxplot() +
20   labs(title = "Intensitat segons el Costat", x = "Costat", y = "
      Intensitat") +
21   theme_minimal() + scale_fill_brewer(palette = "Set2")
22
23 p4 <- ggplot(df, aes(x = day, y = pixel)) +
24   geom_point(alpha = 0.3) +
25   geom_smooth(method = "loess", color = "red") +
26   labs(title = "Tendència mitjana de la intensitat en el temps",
27         x = "Dia", y = "Pixel") +
28   theme_minimal()
29
30 grid.arrange(p1, p3, p4, ncol = 1)
31 print(p2)

```

Listing 3: Gràfics descriptius

A.4 Propostes de models i comparació

```

1 library(lme4)
2 library(MuMIn)
3 m0_ols <- lm(pixel ~ day + I(day^2) + Side, data = df)
4 m1_int <- lmer(pixel ~ day + I(day^2) + Side + (1 | Dog), data = df,
5               , REML = FALSE)
6
7 m2_slp <- lmer(pixel ~ day + I(day^2) + Side + (1 + day | Dog),
8               data = df, REML = FALSE)
9
10 print(anova(m1_int, m2_slp))
11
12 r2_m1 <- r.squaredGLMM(m1_int)
13 print(r2_m1)
14
15 m1_no_side <- lmer(pixel ~ day + I(day^2) + (1 | Dog), data = df,
16                 REML = FALSE)
17 print(anova(m1_no_side, m1_int))
18 m_final <- m2_slp

```

Listing 4: Models

A.5 Verificació de hipòtesis y diagnòstic

```

1 # 1. Extracció de Residus i Ajustats
2 residus <- resid(m_final)
3 ajustats <- predict(m_final)
4

```

```

5 # 2. Gràfic de Linealitat (Residus vs Ajustats)
6 png("diag_linealitat.png", width = 800, height = 600)
7 plot(ajustats, residus, pch = 19, col = "steelblue",
8      main = "Residus vs Valors Ajustats", xlab = "Ajustats", ylab =
9      "Residus")
10 abline(h = 0, col = "red", lwd = 2)
11 dev.off()
12 # 3. Gràfic de Normalitat (QQ-Plot)
13 png("diag_normalitat.png", width = 800, height = 600)
14 qqnorm(residus, pch = 19, col = "darkgreen")
15 qqline(residus, col = "red", lwd = 2)
16 dev.off()
17
18 # 4. Tests Estadístics de Validesa
19 cat("\n--- TEST DE NORMALITAT (Shapiro-Wilk) ---\n")
20 print(shapiro.test(residus))
21
22 cat("\n--- TEST D'HOMOCEDASTICITAT (Breusch-Pagan) ---\n")
23 m_aux <- lm(residus^2 ~ day + I(day^2) + Side, data = df)
24 print(bptest(m_aux))
25
26 cat("\n--- TEST D'INDEPENDÈNCIA (Durbin-Watson) ---\n")
27 print(dwtest(m_aux))
28
29 cat("\n--- MULTICOL LINEALITAT (VIF) ---\n")
30 print(vif(m_final))
31
32
33 m_final_nlme <- lme(pixel ~ day + I(day^2) + Side,
34                   random = ~ 1 | Dog,
35                   data = df,
36                   method = "REML")
37
38 m_ar1 <- update(m_final_nlme, correlation = corAR1(form = ~ 1 | Dog
39 ))
40 print(anova(m_final_nlme, m_ar1))
41
42 res <- residuals(m_final_nlme, type = "normalized")
43 n <- length(res)
44 df_lag <- data.frame(res_t_minus_1 = res[1:(n-1)], res_t = res[2:n
45 ])
46
47 ggplot(df_lag, aes(x = res_t_minus_1, y = res_t)) +
48   geom_point(color = "steelblue", alpha = 0.6, size = 2.5) +
49   geom_smooth(method = "lm", color = "firebrick", fill = "gray80")
50 +

```

```

50 labs(title = "An lisi d'Autocorrelaci Temporal (Lag-1)",
51       subtitle = "Relaci entre residus consecutius",
52       x = expression(paste("Residu en el temps ", t-1)),
53       y = expression(paste("Residu en el temps ", t))) +
54 theme_light() +
55 geom_vline(xintercept = 0, linetype = "dotted") +
56 geom_hline(yintercept = 0, linetype = "dotted")

```

Listing 5: Tests de diagnostic del model

A.6 Análisis de influencia

```

1 est_influencia <- influence(m_final, group = "Dog")
2 cooks_d <- cooks.distance(est_influencia)
3
4 df_cook <- data.frame(Dog = rownames(cooks_d), CooksD = as.numeric(
5   cooks_d))
6 n_gossos <- length(unique(df$Dog))
7 threshold <- 4 / n_gossos
8 ggplot(df_cook, aes(x = Dog, y = CooksD, fill = CooksD > threshold)
9   ) +
10   geom_bar(stat = "identity", color = "black") +
11   geom_hline(yintercept = threshold, linetype = "dashed", color = "
12     red") +
13   scale_fill_manual(values = c("steelblue", "firebrick")) +
14   labs(title = "Distancia de Cook per Subjecte (Gossos)",
15        subtitle = paste("Llindar:", round(threshold, 3)),
16        x = "Identificador del Gos", y = "Distancia de Cook") +
17   theme_minimal()

```

Listing 6: Calcul de la Distancia de Cook